

UNIVERSIDAD TECNOLÓGICA NACIONAL

Facultad Regional Rosario

5° Año Ingeniería en Sistemas de Información

Cátedra: Ciencia de Datos
Profesora: Martina Di Carlo

Comisión: 502
Grupo N°: 12

Integrantes:

Legajo	Nombre y Apellido	Email
51754	Lucio Mondelli	luciomondelli123@gmail.com
51441	Julia Melgarejo	juliaamelgarejo@gmail.com
50708	Francisco Vacs	franciscovacs@gmail.com
50235	Bruno Pacienza	pacienziabruno@gmail.com
49687	Constanza Dominio	cotidominio@hotmail.com

Trabajo Práctico: Trabajo Práctico Integrador
Año: 2026

Contents

1 Fase de Entendimiento del Negocio	5
1.1 Definición concreta del problema y objetivos	5
1.2 Descripción y justificación de las técnicas que se utilizarán para el trabajo	5
1.2.1 Árboles de Decisión (SPSS Modeler y Python)	5
1.2.2 K-Nearest Neighbors – KNN (Python)	5
1.2.3 Análisis Discriminante Lineal (SPSS Statistics)	6
1.2.4 Regresión Logística (SPSS Statistics)	6
1.3 Elaboración de un plan para el proyecto	6
1.3.1 Fase 1: Entendimiento del Negocio	6
1.3.2 Fase 2: Entendimiento de los Datos	7
1.3.3 Fase 3: Preparación de los Datos	7
1.3.4 Fase 4: Modelado	8
1.3.5 Fase 5: Evaluación	8
2 Fase de Entendimiento de los Datos de vuelos	8
2.1 Descripción de los datos (tipo de variable, valores posibles)	8
2.2 Análisis exploratorio Vuelos	9
2.2.1 Análisis univariante	9
2.2.2 Análisis multivariante de vuelos	20
2.2.3 Matriz de correlación	28
2.2.4 Matriz de covarianza	29
2.3 Evaluación de la calidad de los datos	30
2.3.1 Outliers	30

2.3.2	Valores faltantes	31
3	Fase de Preparación de los Datos	32
3.1	Proceso de limpieza de datos	32
3.2	Especificación de transformaciones realizadas	32
3.3	Especificación de la vista minable	33
4	Fase de Modelado	34
4.1	Estrategia general de entrenamiento y comprobación	34
4.2	Árboles de decisión en SPSS Modeler	35
4.2.1	Preparación específica para el modelo	35
4.2.2	Configuración del modelo	35
4.2.3	Resultados obtenidos	38
4.3	Árboles de decisión en Python	41
4.3.1	Preparación específica para el modelo	41
4.3.2	Configuración del modelo	42
4.3.3	Resultados obtenidos	44
4.4	K-Nearest Neighbors (Python)	46
4.4.1	Preparación específica para el modelo	46
4.4.2	Configuración del algoritmo	46
4.4.3	Resultados obtenidos	47
4.5	Análisis discriminante	48
4.5.1	Preparación específica para el modelo	48
4.5.2	Supuestos	49
4.5.3	Resultados obtenidos	52

4.6	Regresión logística	54
4.6.1	Preparación específica para el modelo	54
4.6.2	Supuestos	55
4.6.3	Resultados obtenidos	60
5	Fase de Evaluación	63
5.1	Comparación final de modelos	63
5.2	Selección del modelo final	65
6	Fase de Entendimiento de los Datos de Clientes	65
6.1	Descripción de los datos (tipo de variable, valores posibles)	65
6.2	Análisis exploratorio	66
6.2.1	Análisis univariante	66
6.2.2	Análisis multivariante	75
6.2.3	Matriz de correlación	78
6.2.4	Matriz de covarianza	79
6.3	Evaluación de la calidad de los datos	80
6.3.1	Outliers	80
6.3.2	Valores Faltantes	81
7	Fase de Preparación de los datos	82
7.1	Proceso de limpieza de datos	82
7.2	Especificación de transformaciones realizadas	82
7.3	Especificación de la vista minable	82
8	Fase de Modelado de Clientes	83

8.1	Estrategia general de análisis descriptivo	83
8.2	Cluster Jerárquico (SPSS Modeler / Python)	84
8.2.1	Preparación específica para el modelo	84
8.2.2	Configuración del algoritmo	84
8.2.3	Resultados obtenidos	85
8.2.4	Perfilado de segmentos	86
8.3	Cluster K-Medias (Python)	90
8.3.1	Preparación específica para el modelo	90
8.3.2	Configuración del algoritmo	91
8.3.3	Resultados obtenidos	92
8.4	Cluster Bietápico (SPSS Modeler / Python)	93
8.4.1	Preparación específica para el modelo	93
8.4.2	Configuración del algoritmo	94
8.4.3	Resultados obtenidos	98
8.4.4	Perfilado de segmentos	99
9	Fase de Evaluación de Clientes	99
9.1	Comparación de los modelos de segmentación	99
9.2	Selección del modelo final y perfilado de segmentos	100
9.3	Análisis de Componentes Principales – PCA (Python)	107

1 Fase de Entendimiento del Negocio

1.1 Definición concreta del problema y objetivos

La aerolínea DS Airlines presenta un problema de insatisfacción de clientes causada por demoras en vuelos, agravada por la falta de anticipación y comunicación de las mismas. Esto puede generar en los clientes, una pérdida de confianza, aumento de reclamos y migración hacia empresas competidoras.

En cuanto a los objetivos de negocio se busca minimizar costos operativos asociados a demoras y mejorar la experiencia del cliente mediante una gestión proactiva de la experiencia del pasajero. Además, se pretende fortalecer el posicionamiento estratégico de la organización a través de una asignación eficiente de beneficios y una mejor toma de decisiones orientada al cliente.

Mientras tanto, lo que buscamos como objetivo de ciencia de datos es desarrollar un agente inteligente capaz de predecir la probabilidad de demora de vuelos, segmentar a los pasajeros según su perfil y generar modelos que permitan asignar beneficios de forma eficiente en función de dichas predicciones y segmentaciones.

1.2 Descripción y justificación de las técnicas que se utilizarán para el trabajo

Para abordar los objetivos, se proponen las siguientes técnicas vistas en clase:

1.2.1 Árboles de Decisión (SPSS Modeler y Python)

Es un modelo predictivo que divide el conjunto de datos en subgrupos cada vez más homogéneos basándose en reglas lógicas. En Modeler, se destaca por su capacidad de generar reglas visuales automáticas, mientras que en Python, usando librerías como *scikit-learn*, permite un control granular de la poda para evitar el sobreajuste.

Es ideal para identificar qué condiciones climáticas o tipos de avión disparan la variable *Demorado*. Al ser un modelo de caja blanca, permite explicar fácilmente al Gerente de Atención al Cliente por qué un vuelo específico fue clasificado como propenso a demora.

1.2.2 K-Nearest Neighbors – KNN (Python)

Es un algoritmo basado en la proximidad que clasifica un nuevo registro analizando los k casos más cercanos en el espacio multidimensional. Se implementará en Python debido a su flexibilidad para manejar grandes volúmenes de datos y a la facilidad para normalizar variables numéricas como *Distancia_vuelo* u *Ocupacion_vuelo*.

Es extremadamente útil para detectar patrones complejos de demora que no son lineales. Si vuelos con características similares, como el mismo aeropuerto, la misma temporada y condiciones de visibilidad semejantes, se demoraron en el pasado, KNN permitirá identificar nuevos casos con alta precisión.

1.2.3 Análisis Discriminante Lineal (SPSS Statistics)

Es una técnica estadística y de aprendizaje automático que busca encontrar una combinación lineal de variables independientes que permita separar de manera óptima dos o más clases. El Análisis Discriminante Lineal (LDA) asume que las variables predictoras siguen una distribución normal y tienen matrices de covarianza iguales, lo que proporciona fronteras de decisión muy eficientes cuando estas premisas se cumplen. Se trabajará en SPSS Statistics para el análisis exploratorio y la validación formal de los supuestos estadísticos, y en Python para su implementación ágil dentro del flujo de predicción masiva.

Es valioso en este proyecto para maximizar la separación entre los vuelos que sufrirán retrasos y los que no, proyectando los datos en un espacio de menor dimensión. Al evaluar variables continuas, el LDA ayuda a trazar una línea de corte clara para la variable Demorado. Esto permite anticiparse con precisión matemática y activar planes de contingencia logística antes de que el cuello de botella se materialice en el aeropuerto.

1.2.4 Regresión Logística (SPSS Statistics)

Es una técnica estadística que modela la probabilidad de que ocurra una variable categórica, como *Demorado* con valores 0 o 1, en función de variables independientes. A través de SPSS Statistics, se obtiene un análisis riguroso de los coeficientes y de la significancia de cada factor.

Dado que la empresa busca minimizar costos, la Regresión Logística es clave para entender el peso real de cada variable. Esto permite descartar variables irrelevantes y focalizar los recursos de beneficios, como vouchers o accesos VIP, solo en los casos donde la probabilidad de impacto sea mayor.

1.3 Elaboración de un plan para el proyecto

A continuación, se presenta el plan de trabajo organizado por fases, siguiendo una adaptación del proceso CRISP-DM al problema de DS Airlines.

1.3.1 Fase 1: Entendimiento del Negocio

Objetivo: Comprender a fondo la problemática de DS Airlines respecto a la insatisfacción de los clientes por demoras no comunicadas.

Tareas:

- Definir formalmente los objetivos del proyecto y los criterios de éxito, considerando la reducción del impacto operativo y la asignación eficiente de beneficios.
- Justificar las técnicas de minería de datos a utilizar: Árboles de Decisión, KNN y Regresión Logística o Análisis Discriminante.

1.3.2 Fase 2: Entendimiento de los Datos

Objetivo: Familiarizarse con los datasets proporcionados, *vuelos.xls* y *clientes.xls*, y descubrir los primeros patrones relevantes.

Tareas:

- Realizar la recolección e integración inicial de los datos.
- Describir las variables disponibles, incluyendo tipos de datos y valores posibles.
- Desarrollar el Análisis Exploratorio de Datos (EDA), contemplando análisis univariado mediante histogramas, boxplots y gráficos de barras, además de análisis bivariado.
- Evaluar la calidad de los datos mediante la detección de valores nulos (NAs), valores atípicos (outliers) y un análisis de correlación inicial entre variables predictoras y la variable objetivo, demora.

1.3.3 Fase 3: Preparación de los Datos

Objetivo: Construir el conjunto de datos final, o vista minable, que se utilizará para alimentar las herramientas de modelado.

Tareas:

- Limpiar los datos mediante la eliminación de variables irrelevantes que no aporten valor predictivo, por ejemplo *id_vuelo*.
- Transformar y seleccionar características, tratando la multicolinealidad detectada; por ejemplo, descartar *distancia_vuelo* en favor de *tiempo_estimado_vuelo* debido a su alta correlación.
- Adecuar los datos para los algoritmos mediante la normalización de variables numéricas, esencial para KNN en Python, y la codificación de variables categóricas.
- Generar la vista minable final estructurada para SPSS Modeler, SPSS Statistics y *scikit-learn*.

1.3.4 Fase 4: Modelado

Objetivo: Aplicar las técnicas predictivas seleccionadas para identificar la probabilidad de demora.

Tareas:

- Particionar el dataset en conjuntos de entrenamiento (80%) y prueba o validación (20%).
- Entrenar Árboles de Decisión, utilizando el algoritmo C&R Tree en SPSS Modeler y *scikit-learn* en Python, para extraer reglas lógicas basadas en variables clave como *visibilidad* y *condiciones_climaticas*.
- Implementar K-Nearest Neighbors (KNN) en Python para detectar patrones de proximidad no lineales.
- Ejecutar Regresión Logística y Análisis Discriminante en SPSS Statistics para evaluar el peso estadístico de cada factor.

1.3.5 Fase 5: Evaluación

Objetivo: Determinar qué modelo responde mejor a los objetivos de negocio de DS Airlines, priorizando la detección efectiva de vuelos demorados.

Tareas:

- Analizar las matrices de confusión de cada modelo, comparando la fase de entrenamiento con la de validación.
- Calcular y comparar métricas de rendimiento, principalmente Exactitud (Accuracy) y Precisión.
- Ajustar hiperparámetros y la matriz de costos, penalizando los falsos positivos, es decir, vuelos detectados como demorados que no lo son, para mejorar la Precision. Desde la perspectiva del negocio, es preferible no detectar un vuelo demorado que darle los beneficios de la demora a pasajeros de forma innecesaria, malgastando recursos.

2 Fase de Entendimiento de los Datos de vuelos

2.1 Descripción de los datos (tipo de variable, valores posibles)

Basándonos en los archivos *vuelos.xls*, analizaremos las variables disponibles, descartando primariamente variables como *id_vuelo*, ya que no son relevantes y no aportan valor de utilidad para el análisis objetivo.

A continuación, se describen las variables de la base de datos de vuelos, teniendo en cuenta su tipo y sus posibles valores.

Variable	Tipo	Valores posibles
<i>aeropuerto_origen</i>	Categórica	TUC, MEX, BRC, entre otros
<i>aeropuerto_destino</i>	Categórica	EZE, BOG, LIM, entre otros
<i>hora_salida_programada</i>	Fecha	[00:00;23:59]
<i>dia_semana</i>	Categórica	Lunes, Martes, Miercoles, Jueves, Viernes, Sábado, Domingo
<i>distancia_vuelo</i>	Numérica Discreta	[35;10050]
<i>condiciones_climaticas</i>	Categórica	Despejado, Lluvia, Niebla, Nublado, Tormenta
<i>congestion_aerea</i>	Categórica	Baja, Media, Alta
<i>tipo_avion</i>	Categórica	Airbus A330, Boeing 737, entre otros
<i>ocupacion_vuelo</i>	Numérica Continua	[9.2;99.8]
<i>temporada_alta</i>	Binaria	T/F
<i>puerta_embarque</i>	Numérica discreta	[1;49]
<i>visibilidad</i>	Numérica Continua	[0.2;30.0]
<i>tiempo_estimado_vuelo</i>	Numérica Discreta	[22;802]
<i>demora</i>	Binaria	1/0

Table 1: Variables de vuelo.

2.2 Análisis exploratorio Vuelos

En esta sección se organizará el análisis exploratorio de los datos, separando el estudio univariante y multivariante. Primero se analizarán las variables de manera individual de la base de datos *vuelos.xls* y luego se estudiarán relaciones entre variables.

2.2.1 Análisis univariante

Variables numéricas A continuación, se presentan los gráficos correspondientes al análisis univariante de las variables numéricas de la base de vuelos.

Variable Distancia_Vuelo

Estadístico	Valor
<i>Media</i>	1811.7096
<i>Desvío</i>	2276.6508
<i>Min</i>	35.0000
<i>1er Cuartil</i>	300.0000
<i>2do Cuartil</i>	960.0000
<i>3er Cuartil</i>	2620.0000
<i>Max</i>	10050.0000

Table 2: Estadísticos distancia_vuelo.




Figure 1: Distribución de la variable distancia_vuelo.

En el gráfico se observa que la mayoría de los valores de la variable *distancia_vuelo* se sitúan entre 0 y 2000 km. Dejandonos ver que el mayor porcentaje de vuelos de este conjunto de datos son de distancia corta. Esto se puede confirmar verificando que el 75% de los vuelos son de 2620km o menos mientras que existen vuelos con distancias mucho mayores (10050km).

Variable ocupacion_vuelo

Estadístico	Valor
<i>Media</i>	71.3819
<i>Desvío</i>	15.9654
<i>Min</i>	9.2000
<i>1er Cuartil</i>	61.0750
<i>2do Cuartil</i>	73.4000
<i>3er Cuartil</i>	83.8000
<i>Max</i>	99.8000

Table 3: Estadísticos ocupacion_vuelo.




Figure 2: Distribución de la variable ocupacion_vuelo.

En cuanto al histograma de *ocupacion_vuelo*, se observa que la ocupación se encuentra entre un 60% y un 100%, con un pico en 80%.

Variable visibilidad

Estadístico	Valor
<i>Media</i>	15.3719
<i>Desvío</i>	8.6334
<i>Min</i>	0.2000
<i>1er Cuartil</i>	8.1000
<i>2do Cuartil</i>	15.6000
<i>3er Cuartil</i>	22.9000
<i>Max</i>	30.0000

Table 4: Estadísticos variable visibilidad.




Figure 3: Distribución de la variable visibilidad.

Respecto de la variable *visibilidad*, los datos no presentan variaciones significativas, sino que tienden a ser más estables, rondando los 600 km.

Variable tiempo_estimado_vuelo

Estadístico	Valor
<i>Media</i>	169.8744
<i>Desvío</i>	171.0105
<i>Min</i>	22.0000
<i>1er Cuartil</i>	58.0000
<i>2do Cuartil</i>	103.000
<i>3er Cuartil</i>	220.000
<i>Max</i>	802.000

Table 5: Estadísticos tiempo_estimado_vuelo.




Figure 4: Distribución de la variable tiempo_estimado_vuelo.

Para la variable *tiempo_estimado_vuelo*, se nota una gran crecida entre 20 y 150 aproximadamente, lo cual indica un rango más probable y certero de tiempo.

Variable puerta_embarque

Estadístico	Valor
<i>Media</i>	25.0522
<i>Desvío</i>	14.1306
<i>Min</i>	1.0000
<i>1er Cuartil</i>	13.000
<i>2do Cuartil</i>	25.000
<i>3er Cuartil</i>	37.000
<i>Max</i>	49.000

Table 6: Estadísticos puerta_embarque.




Figure 5: Distribución de la variable `puerta_embarque`.

Para la variable *puerta_embarque*, se observa una distribución bastante uniforme entre los valores 1 y 50 aproximadamente, sin picos pronunciados ni concentraciones significativas en puertas particulares. Esto indica que las puertas de embarque son utilizadas de manera relativamente equilibrada en el conjunto de datos..

Variables categóricas A continuación, se presentan los gráficos correspondientes al análisis univariante de las variables categóricas de la base de vuelos.

Variable `dia_semana`




Figure 6: Distribución de vuelos por día de semana.

La distribución de vuelos por día de semana es bastante pareja, con una leve pero notoria superioridad en el día viernes. Desde allí, la cantidad de vuelos va cayendo poco a poco durante el fin de semana y luego en los días hábiles, terminando en martes como el día con menor cantidad de vuelos.

Variable condiciones_climaticas




Figure 7: Distribución de vuelos por condición climática.

La distribución de vuelos por condición climática deja ver que la mayoría de los vuelos salen cuando el clima está despejado, aunque también hay una cantidad relevante de vuelos con clima nublado. En cambio, son pocos los vuelos que salen con tormenta o niebla.

Variable congestion_aerea




Figure 8: Distribución de vuelos por congestión aérea.

Los datos de la variable *congestion_aerea* exponen que la congestión se concentra principalmente entre las categorías Baja y Media, mientras que la categoría Alta ocurre con menor frecuencia.

Variable tipo_avion




Figure 9: Distribución de vuelos por tipo de avión.

Se diferencian tres grupos con cantidades de vuelos similares: del ATR 72 al Airbus A320 se

encuentran los tipos de aviones que más vuelan; del Boeing 757 al Boeing 737 MAX aparece un grupo intermedio; y del Boeing 777 al Boeing 787 se ubican los tipos de aviones con menor cantidad de vuelos.

Variable demoras




Figure 10: Proporción de vuelos demorados y a tiempo.

Respecto a la cantidad de vuelos demorados frente a vuelos a tiempo, el gráfico de torta muestra que casi el 70% de los vuelos respetan el horario de partida, mientras que el 31,7% presentan demora.

Variable país_origen




Figure 11: Distribución de vuelos por país de origen.

El gráfico de vuelos por país de origen presenta una gran predominancia del aeropuerto de Colombia, seguido por los aeropuertos de Argentina y Brasil. Luego, la cantidad de vuelos decae de forma un poco más brusca aunque suave, dejando a Francia como el país con menor cantidad de vuelos.

Variable país_destino




Figure 12: Distribución de vuelos por país de destino.

La distribución de vuelos por país de destino resulta considerablemente similar a la de origen, con Colombia como el país con mayor cantidad de vuelos y Francia como el país con menor cantidad.

Variable `franja_horaria`




Figure 13: Distribución de vuelos por franja horaria.

Respecto al gráfico de vuelos por franja horaria, se observa una clara predominancia de los vuelos de mañana-tarde sobre los vuelos de noche-madrugada.

2.2.2 Análisis multivariante de vuelos




Figure 14: Relación entre demora y condiciones climáticas.

La condición despejado es la que concentra más vuelos en total y mantiene una buena proporción a favor de los vuelos a tiempo, con casi 5000 vuelos a tiempo contra 1800 demorados. Nublado también presenta una cantidad importante de vuelos y una proporción pareja. Tormenta tiene pocos vuelos en total, con una proporción pareja entre demorados y a tiempo, aunque con más vuelos demorados. La niebla también muestra una proporción desfavorable, con casi tantos vuelos demorados como vuelos a tiempo.

Para complementar el análisis anterior, agrupamos la variable *visibilidad* en tres rangos. Estos rangos fueron definidos tomando como referencia los estándares de la Organización de Aviación Civil Internacional (OACI), utilizados para clasificar condiciones de vuelo visual (VFR), vuelo instrumental (IFR) y el concepto CAVOK (*Ceiling And Visibility OK*).¹ Tomando esto en cuenta, las categorías que definimos son: **Mala** agrupa visibilidades menores a 5 km, asociadas a condiciones IFR o Low IFR; la categoría **Regular** incluye valores entre 5 km y 8 km, correspondientes a condiciones marginales para vuelo visual; y la categoría **Buena** contempla valores mayores a 8 km, generalmente compatibles con condiciones VFR o CAVOK.

¹ICAO, *Annex 2 to the Convention on International Civil Aviation: Rules of the Air*, 10.^a ed. (Montreal: ICAO, 2005), Cap. 4; ICAO, *Annex 3 to the Convention on International Civil Aviation: Meteorological Service for International Air Navigation*, 20.^a ed. (Montreal: ICAO, 2018).




Figure 15: Relación entre condición climática y rango de visibilidad.

En la gráfica resultante se observa que las condiciones climáticas más adversas, como niebla y tormenta, concentran una mayor proporción de casos con visibilidad mala o regular, lo cual es consistente con la clasificación definida. A su vez, la mayoría de los casos despejados se concentran en visibilidad buena. Sin embargo, aparecen algunos registros con visibilidad mala incluso en condiciones nubladas y, principalmente, despejadas. Estos casos podrían tratarse como posibles valores atípicos o inconsistencias de medición, ya que no coinciden completamente con lo esperable desde el punto de vista meteorológico. Por este motivo, conviene revisarlos con mayor detalle antes de decidir si deben corregirse, descartarse o mantenerse en la vista minable.




Figure 16: Relación entre demora y congestión aérea.

En el gráfico se observa que la congestión media y baja tienen una diferencia significativa a favor de los vuelos a tiempo. Con congestión alta, la proporción entre vuelos demorados y a tiempo es bastante pareja. A partir de esto, se puede concluir que a mayor congestión aérea existen más chances de demora.




Figure 17: Relación entre demora y tipo de avión.

En general, todos los tipos de aviones presentan una proporción similar entre cantidad de vuelos

demorados y no demorados, por lo que no parecería que el tipo de avión influya de gran manera sobre la demora de los vuelos.




Figure 18: Distribución de la distancia de vuelo por tipo de avión.

En este gráfico se observa la distribución y el alcance de la variable *distancia_vuelo* según el *tipo_avion*. Los aviones de mayor porte, como Boeing 777, Boeing 787, Airbus A330 y Airbus A350, concentran vuelos de mayor distancia y presentan rangos más amplios, llegando cerca de los 10000 km. En cambio, modelos como Airbus A320, Embraer E190, ATR 72 y Boeing 737 se asocian principalmente a vuelos de menor distancia. Esto indica que el tipo de avión está relacionado con la distancia recorrida, aunque no necesariamente implica por sí solo una mayor probabilidad de demora.

Al observar que existían muchos tipos de avión diferentes, decidimos reclasificarlos en una variable más general según el tipo de fuselaje. Para este análisis operativo de la flota, los modelos de aeronaves fueron recategorizados siguiendo una clasificación estándar de la industria aeroespacial, basada en lineamientos técnicos de fabricantes como Airbus y Boeing, y en criterios utilizados por la OACI. Esta clasificación permite agrupar los aviones según características operativas relevantes, como capacidad, alcance y requerimientos aeroportuarios.

La primera categoría corresponde a **fuselaje angosto** (*narrow-body* o *single-aisle*), que incluye aeronaves con un solo pasillo en la cabina de pasajeros y un diámetro de fuselaje aproximado de entre 3 y 4 metros. Estos aviones están diseñados principalmente para rutas de corto y medio alcance. En esta categoría se incluyeron modelos como la familia Boeing 737, la familia Airbus A320, Embraer E190/195 y ATR 72.

La segunda categoría corresponde a **fuselaje ancho** (*wide-body* o *twin-aisle*), que agrupa aeronaves con dos pasillos y un diámetro de fuselaje típicamente superior a 5 metros. Estos aviones suelen utilizarse en rutas de largo alcance y vuelos transoceánicos de alta capacidad. En esta categoría se incluyeron modelos como Airbus A330, Airbus A350, Boeing 777 y Boeing 787.




Figure 19: Distribución de la distancia de vuelo por tipo de fuselaje.

En este gráfico se confirma la lógica de la recategorización: los aviones de fuselaje ancho se asocian principalmente con vuelos de mayor distancia, mientras que los aviones de fuselaje angosto concentran vuelos de menor alcance. Esto respalda la decisión de agrupar los modelos por fuselaje, ya que la nueva variable sintetiza mejor las diferencias operativas entre aeronaves y reduce la cantidad de categorías del atributo original *tipo_avion*.




Figure 20: Distribución de la ocupación de vuelo por tipo de fuselaje.

Al analizar la ocupación por tipo de fuselaje, se observa que tanto los aviones de fuselaje ancho como los de fuselaje angosto presentan niveles de ocupación similares. Esto indica que el tamaño del avión o la distancia del vuelo no implican necesariamente una mayor ocupación. Incluso en vuelos más largos y con aviones más grandes, siguen existiendo asientos vacíos, por lo que la variable *ocupacion_vuelo* debe analizarse de forma independiente del tipo de fuselaje.




Figure 21: Relación entre demora y día de semana.

A lo largo de toda la semana, tanto la cantidad total de vuelos como la proporción entre vuelos demorados y vuelos a tiempo resulta similar. Esto indica que el día de la semana tiene un impacto leve en la demora y probablemente no sea una de las variables más determinantes del modelo.




Figure 22: Relación entre demora y temporada alta.

En temporada baja hay casi 7000 vuelos a tiempo contra unos 2800 demorados, mientras que en temporada alta la proporción se acorta, con unos 3300 vuelos a tiempo y 2000 demorados. Esto

sugiere que volar en temporada alta aumenta las chances de sufrir una demora. Si bien la temporada baja concentra más vuelos en total, el efecto es visible y tiene sentido incluir esta variable en el modelo.




Figure 23: Relación entre demora y franja horaria.

La relación bivalente entre la variable *franja_horaria* y la variable objetivo *demora* nos indica que no hay una relación directa entre la franja horaria y la demora de los vuelos ya que hay un proporción similar de demorados y a tiempo en todas




Figure 24: Relación entre demora y país de origen.

En esta relación bivalente entre la variable país de origen y la variable objetivo *demora* también podemos observar que en todos los países hay una relación similar entre demorados y no demorados por lo cual suponemos que no será una variable determinante a la hora de predecir la demora.

2.2.3 Matriz de correlación




Figure 25: Matriz de correlación entre las variables.

En la matriz de correlación se observa una relación muy fuerte entre *distancia_vuelo* y *tiempo_estimado_vuelo*, lo cual resulta coherente, ya que a mayor distancia recorrida se espera una mayor duración del vuelo. En el resto de las variables no se aprecian correlaciones lineales fuertes.

2.2.4 Matriz de covarianza

La matriz de covarianza permite analizar cómo varían conjuntamente las variables numéricas del dataset. A diferencia de la matriz de correlación, sus valores dependen de la escala original de cada variable, por lo que se utiliza como complemento para identificar relaciones de variación conjunta entre los atributos.




Figure 26: Matriz de covarianza entre las variables.

En la matriz de covarianza se observa una covarianza positiva destacada entre *distancia_vuelo* y *tiempo_estimado_vuelo*, lo que confirma que ambas variables tienden a aumentar de manera conjunta. Este resultado coincide con lo observado en la matriz de correlación y refuerza la idea de que ambas variables contienen información similar. También se debe tener en cuenta que los valores de covarianza pueden verse influenciados por la escala de cada variable, por lo que su interpretación debe complementarse con la matriz de correlación. En general, no se identifican nuevas relaciones suficientemente relevantes como para descartar otras variables en esta etapa.

2.3 Evaluación de la calidad de los datos

2.3.1 Outliers

Para identificar valores atípicos nos basamos en los gráficos de caja y bigotes de las variables numéricas de vuelos. Como criterio general utilizamos la regla del rango intercuartílico, según la cual todos los valores que quedan por fuera de los bigotes se consideran posibles outliers.

Primero analizamos la variable *distancia_vuelo*. En el boxplot se observa que todos los valores superiores a 5500 km podrían considerarse atípicos. De este modo, decidimos verificar los valores más extremos, con lo cual pudimos comprobar que todos los vuelos con distancias superiores a los 10000km corresponden a vuelos realizados desde EZE a MAD o viceversa, lo cual coincide con la distancia real entre esos aeropuertos. Por este motivo, concluimos mantener los valores atípicos de esta variable.

Siguiendo la misma lógica, analizamos los valores atípicos de la variable *ocupacion_vuelo*. Según el gráfico de caja, los vuelos con menos del 25% de los asientos ocupados se consideran outliers. Sin embargo, siempre que un vuelo cuente con una ocupación mayor al 0%, será tenido en cuenta, ya que independientemente de la cantidad de pasajeros transportados, nos interesa conocer si el vuelo se demoró o no.

También se identifican outliers en la variable *tiempo_estimado_vuelo*, especialmente para aquellos valores mayores a 550 minutos. Sin embargo, siguiendo el mismo procedimiento que con *distancia_vuelo*, pudimos verificar que incluso los vuelos de mayor duración, cercanos a 800 minutos, fueron realizados desde EZE a MAD o viceversa, lo cual coincide con lo analizado en la variable de distancia, y con la duración real de estos vuelos. Por lo tanto, tampoco descartaremos estos valores atípicos.

Por último, verificamos los registros en los que las condiciones climáticas eran *Despejado*, *Nublado* o *Lluvia*, pero aparecían asociadas a visibilidad baja. En total encontramos 22 vuelos con estas características y todos tenían *visibilidad* igual a 5. Por esta razón, decidimos que el valor 5 sea incluido dentro de la categoría de visibilidad media y no dentro de visibilidad baja.

Condiciones climáticas	Vuelos encontrados
Despejado	10
Nublado	7
Lluvia	5
Total	22

Table 7: Resumen de vuelos con condiciones climáticas no severas y visibilidad igual a 5.

ID vuelo	Condiciones climáticas	Visibilidad	Tiempo estimado de vuelo	Demora
10022	Despejado	5.0	231	0
10976	Despejado	5.0	30	0
12144	Despejado	5.0	72	0
12973	Despejado	5.0	407	1
16372	Despejado	5.0	41	0
16481	Despejado	5.0	199	0
20698	Despejado	5.0	44	1
21727	Despejado	5.0	338	0
22516	Despejado	5.0	89	1
23733	Despejado	5.0	64	1
12789	Nublado	5.0	326	1
14006	Nublado	5.0	118	1
15941	Nublado	5.0	174	1
16159	Nublado	5.0	314	0
18011	Nublado	5.0	43	0
21707	Nublado	5.0	121	0
25603	Nublado	5.0	68	0
11287	Lluvia	5.0	85	0
18512	Lluvia	5.0	165	1
21999	Lluvia	5.0	43	1
22511	Lluvia	5.0	380	0
25025	Lluvia	5.0	108	1

Table 8: Detalle de vuelos detectados con visibilidad igual a 5 y condiciones climáticas despejado, nublado o lluvia.

2.3.2 Valores faltantes

La siguiente tabla muestra las diferentes variables de la base de datos de vuelos, la cantidad de valores no nulos y el tipo de dato asociado. En este caso hay 15000 registros en total y todas las variables tienen esa misma cantidad de *non-null count*, por lo que no hay valores nulos en la tabla.

N°	Variable	Valores no nulos
1	<i>aeropuerto_origen</i>	15000
2	<i>aeropuerto_destino</i>	15000
3	<i>hora_salida_programada</i>	15000
4	<i>dia_semana</i>	15000
5	<i>distancia_vuelo</i>	15000
6	<i>condiciones_climaticas</i>	15000
7	<i>congestion_aerea</i>	15000
8	<i>tipo_avion</i>	15000
9	<i>ocupacion_vuelo</i>	15000
10	<i>temporada_alta</i>	15000
11	<i>puerta_embarque</i>	15000
12	<i>visibilidad</i>	15000
13	<i>tiempo_estimado_vuelo</i>	15000
14	<i>demora</i>	15000

Table 9: Cantidad de valores no nulos por variable en la base de datos de vuelos.

3 Fase de Preparación de los Datos

3.1 Proceso de limpieza de datos

Al no haber valores nulos y al no descartar outliers, no vamos a realizar una limpieza por eliminación de registros sobre el dataset. Sin embargo, sí se decidió eliminar la variable *distancia_vuelo* y conservar *tiempo_estimado_vuelo*, ya que ambas presentan una relación muy fuerte y aportan información similar.

También se eliminó la variable *id_vuelo* debido a su alta cardinalidad. Esta variable funciona como un identificador único de cada registro y no aporta información estructural útil para el modelo. Mantenerla podría provocar sobreajuste (*overfitting*), ya que el modelo tendería a memorizar vuelos individuales en lugar de aprender patrones generales asociados a las demoras.

3.2 Especificación de transformaciones realizadas

A partir del análisis exploratorio y multivariante realizado, se definieron algunas transformaciones para simplificar la vista minable y mejorar la capacidad de interpretación de los modelos. El objetivo de estas transformaciones fue reducir la granularidad de ciertas variables, agrupar categorías con comportamiento similar y representar mejor las relaciones observadas con la variable objetivo

demora.

En primer lugar, se transformó la variable horaria *hora_salida_programada* en franjas horarias. Esta decisión se tomó porque, para el análisis predictivo, resulta más útil identificar si un vuelo sale por la mañana, tarde, noche o madrugada que trabajar con cada hora exacta de salida. Además, en el análisis multivariante se observó que la demora podía analizarse mejor al comparar grupos horarios, ya que ciertos momentos del día pueden estar asociados a mayor congestión operativa o acumulación de retrasos previos.

En segundo lugar, los aeropuertos de origen y destino se agruparon por país. Esta transformación permite pasar de una categoría muy específica, como el aeropuerto puntual, a una representación más general del contexto geográfico del vuelo. A partir de los análisis multivariantes por país de origen y destino, se buscó conservar patrones asociados a rutas internacionales o nacionales sin generar demasiadas categorías dispersas. De esta manera, los modelos pueden captar diferencias entre países sin depender exclusivamente de cada aeropuerto individual.

Por último, los tipos de avión se agruparon según el tipo de fuselaje. Esta decisión se basó en el análisis multivariante realizado entre *tipo_avion*, *ocupacion_vuelo* y *demora*, donde se buscó entender si las características operativas de las aeronaves podían relacionarse con la probabilidad de retraso. Agrupar por fuselaje permite representar diferencias generales de capacidad y operación entre aeronaves, evitando que el modelo trabaje con categorías demasiado específicas de modelos de avión.

En conjunto, estas transformaciones permiten construir una base más consistente para el modelado, reduciendo ruido, mejorando la interpretabilidad y manteniendo la información relevante detectada durante el análisis multivariante.

3.3 Especificación de la vista minable

Luego de aplicar el proceso de limpieza y las transformaciones definidas, se construyó la vista minable que será utilizada para la etapa de modelado. En esta versión final se eliminaron las variables *id_vuelo* y *distancia_vuelo*, y se incorporó la variable transformada *tipo_fuselaje*, manteniendo únicamente los atributos considerados relevantes para predecir la variable objetivo *demora*.

N°	Variable	Valores no nulos	Tipo de variable
0	<i>aeropuerto_origen</i>	15000	Catagórica
1	<i>aeropuerto_destino</i>	15000	Catagórica
2	<i>franja_horaria</i>	15000	Catagórica
3	<i>dia_semana</i>	15000	Catagórica
4	<i>condiciones_climaticas</i>	15000	Catagórica
5	<i>congestion_aerea</i>	15000	Catagórica
6	<i>ocupacion_vuelo</i>	15000	Numérica continua
7	<i>temporada_alta</i>	15000	Binaria
8	<i>visibilidad</i>	15000	Numérica continua
9	<i>tiempo_estimado_vuelo</i>	15000	Numérica discreta
10	<i>demora</i>	15000	Binaria
11	<i>tipo_fuselaje</i>	15000	Catagórica

Table 10: Vista minable del dataset vuelos.

Esta vista minable conserva las variables catagóricas, binarias y numéricas necesarias para aplicar los algoritmos seleccionados.

4 Fase de Modelado

4.1 Estrategia general de entrenamiento y comprobación

Primero se verificó la distribución de la clase a predecir en el dataset original. Como se observa en la siguiente tabla, la variable *demora* no se encuentra balanceada, ya que predominan los vuelos sin demora.

Demora	Cantidad
0	10222
1	4778

Table 11: Distribución inicial de la variable objetivo en el dataset completo.

Luego se separó el dataset en 80% entrenamiento y 20% comprobación, pero garantizando que la proporción de la clase demora se mantenga igual en ambos conjuntos, a través de la estratificación. Este proceso se realizó de forma aleatoria pero reproducible.

Como criterio general de evaluación, todos los modelos fueron analizados principalmente a partir de la matriz de confusión y de las métricas *Accuracy* y *Precision*. Sin embargo, para el problema de DS Airlines se decidió priorizar la *Precision* de la clase demora por sobre el *Accuracy*, ya que el objetivo principal es minimizar los costos que puede generar un falso positivo.

Esta decisión se fundamenta en que los falsos positivos representan el error más crítico para el negocio: corresponden a vuelos que no estaban demorados pero que el modelo clasifica como demorados. En esos casos, la empresa estaría activando beneficios a clientes que no los precisan y utilizando recursos económicos de forma poco eficiente. Por ese motivo, se aceptó cierto aumento de falsos negativos siempre que permitiera reducir los falsos positivos y reducir los costos de la empresa en vouchers.

De todos modos, la mejora del *Precision* no se evaluó de forma aislada. También se buscó mantener un *Accuracy* razonable, aproximadamente entre 60% y 70%, para que el modelo no pierda completamente capacidad de clasificación general. Por lo tanto, el criterio de selección consistió en buscar un equilibrio entre detectar la cantidad justa de vuelos demorados y conservar un desempeño global aceptable.

Debido a las diferencias entre las técnicas utilizadas, cada modelo requirió configuraciones y estrategias particulares de preprocesamiento, parametrización y tratamiento del desbalance de clases. Por este motivo, la preparación específica, los parámetros y los resultados se presentan por separado para cada técnica.

4.2 Árboles de decisión en SPSS Modeler

4.2.1 Preparación específica para el modelo

Para el árbol de decisión en SPSS Modeler se utilizó la vista minable tal como fue definida en la fase de preparación de los datos. Es decir, no se construyó una vista alternativa para esta herramienta, sino que se trabajó con las variables ya seleccionadas y transformadas previamente.

Como se mencionó en la estrategia general de entrenamiento y comprobación, para este modelo se utilizó la misma partición definida para el resto de las técnicas, respetando el criterio común de comparación entre modelos.

Para este modelo no fue necesario eliminar variables numéricas ni discretizarlas manualmente. Esto se debe a que el algoritmo de árbol de decisión selecciona automáticamente los puntos de corte más convenientes para separar los registros según la variable objetivo *demora*. Por lo tanto, variables como *visibilidad*, *ocupacion_vuelo* o *tiempo_estimado_vuelo* pudieron ser utilizadas directamente por el modelo.

4.2.2 Configuración del modelo

Se utilizó el algoritmo C&R Tree debido a su buen desempeño en tareas de clasificación, su capacidad para trabajar con variables continuas y categóricas, y la facilidad de interpretación de los resultados obtenidos mediante reglas y nodos de decisión. Esta característica resulta adecuada para el problema planteado, ya que permite explicar de manera clara qué condiciones aumentan la probabilidad de que un vuelo sea clasificado como demorado.

Para esta primera configuración del modelo se trabajó con la profundidad máxima predeterminada de 5 niveles. Además, se mantuvo activa la poda del árbol (*pruning*) con el objetivo de evitar el sobreajuste, es decir, impedir que el modelo se adapte demasiado a los datos de entrenamiento y pierda capacidad de generalización sobre el conjunto de comprobación.

Inicialmente, el modelo se entrenó sin modificar los costos de clasificación errónea. Esto significa que todos los errores tenían el mismo peso para el algoritmo: clasificar un vuelo demorado como no demorado tenía el mismo costo que clasificar un vuelo no demorado como demorado. Esta primera prueba permitió obtener una línea base para evaluar el comportamiento del árbol antes de aplicar ajustes orientados a mejorar la detección de la clase *demora*.

Como parte de esta configuración inicial, se obtuvo un primer árbol sin costos diferenciados. Esta salida se utiliza como referencia para justificar posteriormente la decisión de asignar mayor peso a los falsos positivos.




Figure 27: Primer árbol de decisión generado en SPSS Modeler sin costos de clasificación errónea diferenciados.

También se analizó la importancia relativa de los predictores en esta primera configuración. Se observa que *visibilidad* fue la variable con mayor importancia, seguida por variables como *congestion_aerea*, *pais_origen*, *tiempo_estimado_vuelo*, *ocupacion_vuelo*, *pais_destino* y *condiciones_climaticas*.




Figure 28: Importancia de predictores del primer árbol sin costos diferenciados.

Finalmente, se revisó la matriz de confusión de esta primera configuración. Esta evaluación inicial permite observar cómo se comporta el modelo cuando todos los errores tienen el mismo costo y sirve como punto de comparación para el ajuste posterior de la matriz de costos.

Real \ Predicción	0	1
0	7781	439
1	3115	694

Table 12: Matriz de confusión del primer árbol sin costos diferenciados en el conjunto de entrenamiento.

Real \ Predicción	0	1
0	1912	90
1	789	180

Table 13: Matriz de confusión del primer árbol sin costos diferenciados en el conjunto de comprobación.

A partir de las matrices de confusión anteriores, se calcularon las métricas principales para entrenamiento y comprobación.

Para el conjunto de entrenamiento, el Accuracy se calculó como:

$$\text{Accuracy_entrenamiento} = \frac{7781 + 694}{7781 + 439 + 3115 + 694} = \frac{8475}{12029} = 0,7045$$

La *Precision* de la clase demora en entrenamiento fue:

$$\text{Precision_entrenamiento} = \frac{694}{694 + 439} = \frac{694}{1133} = 0,6125$$

Para el conjunto de comprobación, el Accuracy se calculó como:

$$\text{Accuracy_comprobación} = \frac{1912 + 180}{1912 + 90 + 789 + 180} = \frac{2092}{2971} = 0,7042$$

La *Precision* de la clase demora en comprobación fue:

$$\text{Precision_comprobación} = \frac{180}{180 + 90} = \frac{180}{270} = 0,6666$$

Al comparar entrenamiento y comprobación, se observa que el Accuracy es prácticamente igual en ambos conjuntos: 70,45% en entrenamiento y 70,42% en comprobación. Lo mismo ocurre con la *Precision*, que se mantiene en valores similares: 61,25% en entrenamiento y 66,66% en comprobación. Esta similitud indica que no se observan señales claras de sobreentrenamiento, ya que el modelo no obtiene resultados mucho mejores en entrenamiento que en comprobación. Tampoco se evidencia una diferencia fuerte que indique un problema de subentrenamiento entre ambos conjuntos.

Sin embargo, aunque consideramos que la *Precision* de la clase demora no es baja, creemos que ajustando los hiperparámetros del árbol podemos hacerla crecer sin perder el *Accuracy* general. Dado que esta es la métrica más relevante para el objetivo del negocio, se decidió modificar los pesos de la matriz de costos para mejorar la misma. En particular, se asignó un peso de 1.5 al error en el que el modelo predice que hay demora, pero en realidad no la hay. Es decir, se penalizaron con mayor fuerza los falsos positivos.

4.2.3 Resultados obtenidos

A continuación, se presenta el árbol obtenido luego de aplicar este cambio en los costos de clasificación errónea.




Figure 29: Árbol de decisión ajustado en SPSS Modeler con mayor peso para falsos positivos.

Al comparar este árbol corregido con el primero, se observa que la variable principal continúa siendo *visibilidad*, con el mismo punto de corte de 5,050. Este umbral resulta coherente con lo analizado previamente en el análisis multivariante, cuando se dividió la variable *visibilidad* según los criterios de la Organización de Aviación Civil Internacional (OACI). En esa clasificación, la visibilidad mala o reducida quedaba asociada a valores cercanos a 5 km o inferiores, por lo que tiene sentido que el árbol utilice un valor próximo para separar situaciones con distinto riesgo de demora.

La diferencia central del árbol corregido es que, al penalizar los falsos positivos, el modelo se vuelve más cuidadoso antes de clasificar un vuelo como demorado. Esto se observa especialmente en la rama de *visibilidad* menor o igual a 5,050: aunque allí la proporción de demoras es mayor, el árbol no asigna automáticamente todos esos casos a la clase demora, sino que vuelve a dividir según *condiciones_climaticas* y luego según *congestion_aerea*. De esta forma, solo algunas combinaciones, como baja visibilidad junto con determinadas condiciones climáticas y niveles de congestión, quedan asociadas a una predicción de demora.

En cambio, para valores de *visibilidad* mayores a 5,050, el árbol conserva una clasificación más general hacia la clase sin demora, ya que en esa rama predominan claramente los vuelos no demorados. Este comportamiento es consistente con el nuevo objetivo del ajuste: mejorar la *Precision* de la clase demora, reduciendo la cantidad de vuelos clasificados como demorados cuando en realidad no lo están. Por eso, el árbol corregido no busca detectar la mayor cantidad posible de demoras, sino emitir menos alertas incorrectas y hacer más confiables las predicciones positivas.

Además, se analizó nuevamente la importancia de los predictores luego del ajuste de costos.




Figure 30: Importancia de predictores del árbol ajustado en SPSS Modeler.

En comparación con el primer árbol, la importancia de los predictores también se modificó. La variable *visibilidad* continúa siendo claramente la más importante y concentra la mayor parte del peso explicativo del modelo. En segundo lugar aparece *congestion_aerea*, seguida por *condiciones_climaticas*. Luego se ubican otras variables con una importancia menor y bastante similar entre sí, como *pais_origen*, *tiempo_estimado_vuelo*, *ocupacion_vuelo* y *pais_destino*.

Esta distribución es coherente con el árbol corregido, ya que la primera división se realiza por *visibilidad* y las divisiones posteriores se apoyan principalmente en *condiciones_climaticas* y *congestion_aerea*. Por lo tanto, el ajuste de costos no cambia la variable dominante del modelo, sino que refuerza el uso de variables complementarias para decidir con mayor cuidado cuándo clasificar un vuelo como demorado, reduciendo así los falsos positivos y mejorando la *Precision*.

Real \ Predicción	0	1
0	7957	263
1	3309	500

Table 14: Matriz de confusión del árbol ajustado en el conjunto de entrenamiento.

Real \ Predicción	0	1
0	1955	47
1	850	119

Table 15: Matriz de confusión del árbol ajustado en el conjunto de comprobación.

A partir de estas matrices, se calcularon las métricas principales para evaluar el impacto del ajuste.

Para el conjunto de entrenamiento, el *Accuracy* fue:

$$\text{Accuracy_entrenamiento} = \frac{7957 + 500}{7957 + 263 + 3309 + 500} = \frac{8457}{12029} = 0,6927$$

La *Precision* de la clase demora en entrenamiento fue:

$$\text{Precision_entrenamiento} = \frac{500}{500 + 263} = \frac{500}{763} = 0,6553$$

Para el conjunto de comprobación, el *Accuracy* fue:

$$\text{Accuracy_comprobación} = \frac{1955 + 119}{1955 + 47 + 850 + 119} = \frac{2074}{2971} = 0,6980$$

La *Precision* de la clase demora en comprobación fue:

$$\text{Precision_comprobación} = \frac{119}{119 + 47} = \frac{119}{166} = 0,7169$$

El ajuste de costos produjo una disminución del *Accuracy* respecto del primer árbol, pero mejoró la *Precision* de la clase demora. En comprobación, la *Precision* pasó de 66,66% a 71,69%. Esto significa que el modelo es mejor detectando las demoras justas, disminuyendo los falsos positivos.

Esta mejora se logró a costa de aumentar los falsos negativos, es decir, casos en los que el modelo predice que no hay demora aunque finalmente exista. Sin embargo, desde la perspectiva de DS Airlines, este intercambio resulta razonable debido a su objetivo de abaratar costos.

4.3 Árboles de decisión en Python

4.3.1 Preparación específica para el modelo

Para el árbol de decisión realizado en Python partimos de la vista minable y usamos todas las variables numéricas previamente definidas sin ninguna modificación. Sin embargo por la naturaleza del método utilizado, tuvimos que transformar todas las variables categóricas a numéricas mediante one-hot encoding, obteniendo por ejemplo: para la variable `franja_horaria` que se divide en madrugada, mañana, tarde, noche, lo que se hace es crear tres columnas de la siguiente manera: `franja_horaria_Mañana` (06-12) - `franja_horaria_Tarde` (12-18) - `franja_horaria_Noche` (18-24). A cada una de estas columnas se le asigna el valor 1 cuando la categoría correspondiente está presente y 0 cuando no lo está. De este modo, las variables utilizadas por el modelo incluyen todas las variables numéricas de la vista minable, junto con las variables categóricas transformadas a formato numérico. Entre ellas se encuentran: `dia_semana`, `condiciones_climaticas`, `congestion_aerea`, `temporada_alta`, `pais_origen`, `pais_destino`, `tipo_fuselaje` y `franja_horaria`. Por último, procedimos a separar los datos en dos sets, uno de entrenamiento y uno de validación con una proporción 80/20 como indicamos en el punto 4.1.

4.3.2 Configuración del modelo

En primera instancia, y siguiendo la misma lógica que para árboles en SPSS decidimos probar un árbol sin modificar los pesos. Dentro de las diferentes profundidades posibles, decidimos utilizar 5 como máxima profundidad porque es el valor que presentó un mejor balance entre *Accuracy* y *Precision*. De este modo, la importancia de los predictores quedó de la siguiente manera:




Figure 31: Importancia de predictores del primer árbol sin costos diferenciados.

La principal diferencia con el árbol de SPSS es que aparecen nuevas variables (dado que las categóricas fueron transformadas a numéricas), pero siguen destacándose entre los predictores más influyentes la visibilidad, la congestión aérea y el clima. De este modo, las matrices de confusión para esta configuración fueron las siguientes:




Figure 32: Matriz de confusión del primer árbol sin costos diferenciados en el conjunto de entrenamiento.




Figure 33: Matriz de confusión del primer árbol sin costos diferenciados en el conjunto de comprobación.

Para el conjunto de entrenamiento, el *Accuracy* fue:

$$\text{Accuracy_entrenamiento} = \frac{5818 + 2146}{5818 + 2360 + 1676 + 2146} = \frac{7964}{12000} = 0,6637$$

La *Precision* de la clase demora en entrenamiento fue:

$$\text{Precision_entrenamiento} = \frac{2146}{2146 + 2360} = \frac{2146}{4506} = 0,4762$$

Para el conjunto de comprobación, el *Accuracy* fue:

$$\text{Accuracy_comprobación} = \frac{1438 + 606}{1438 + 606 + 429 + 527} = \frac{2044}{3000} = 0,6813$$

La *Precision* de la clase demora en comprobación fue:

$$\text{Precision_comprobación} = \frac{527}{527 + 606} = \frac{527}{1133} = 0,4651$$

Al observar los resultados, se puede observar que tanto el *Accuracy* como la *Precision* se mantienen prácticamente invariables entre entrenamiento y comprobación, lo cual indica que no hay señales claras de que el modelo esté sobreentrenado. Ya que la precision da un valor bajo en comparación con lo obtenido en modeler, decidimos probar hacer un árbol pero con asignándole un peso de 2 al error cuando el modelo prediga que hay demora pero en realidad no la hay.

4.3.3 Resultados obtenidos

Frente a este cambio en los pesos, la importancia de las clases predictoras quedó prácticamente invariable. Sin embargo, hubo un gran cambio en las matrices de confusión respecto al modelo anterior.




Figure 34: Matriz de confusión del primer árbol con costos diferenciados en el conjunto de entrenamiento.




Figure 35: Matriz de confusión del primer árbol con costos diferenciados en el conjunto de comprobación.

Para el conjunto de entrenamiento, el *Accuracy* fue:

$$\text{Accuracy_entrenamiento} = \frac{8060 + 366}{8060 + 3456 + 118 + 366} = \frac{8426}{12000} = 0,7021$$

La *Precision* de la clase demora en entrenamiento fue:

$$\text{Precision_entrenamiento} = \frac{366}{366 + 118} = \frac{366}{484} = 0,7561$$

Para el conjunto de comprobación, el *Accuracy* fue:

$$\text{Accuracy_comprobación} = \frac{2002 + 81}{2002 + 42 + 875 + 81} = \frac{2083}{3000} = 0,6943$$

La *Precision* de la clase demora en comprobación fue:

$$\text{Precision_comprobación} = \frac{81}{81 + 42} = \frac{81}{123} = 0,6585$$

Nuevamente podemos notar que hay una variación muy pequeña entre el *Accuracy* y la *Precision* de los datos de entrenamiento y comprobación, lo cual da indicios de que el modelo no está sobreentrenado. Además, si bien a comparación del modelo anterior hubo una caída de aproximadamente 7% en el *Accuracy*, conseguimos aumentar la *Precision* en más del 20%, siendo esta última la medida que definimos como de mayor relevancia para nuestro caso de estudio.

4.4 K-Nearest Neighbors (Python)

4.4.1 Preparación específica para el modelo

A partir de la vista minable, tuvimos que mutar las variables categóricas a variables numéricas, mediante el método one-hot encoding. De este modo, las variables utilizadas por el modelo incluyen todas las variables numéricas de la vista minable, junto con las variables categóricas transformadas a formato numérico. Entre ellas se encuentran: `dia_semana`, `condiciones_climaticas`, `congestion_aerea`, `temporada_alta`, `pais_origen`, `pais_destino`, `tipo_fuselaje` y `franja_horaria`.

Además, antes de aplicar el modelo, estandarizamos los datos porque las escalas de las variables eran muy distintas entre sí. De este modo, se asegura que todas tengan un peso similar.

4.4.2 Configuración del algoritmo

Iniciamos probando diferentes valores de K, bajo la métrica de distancia euclídea, aplicando un método que asigna mayor importancia a los vecinos más cercanos por sobre los más lejanos.

A continuación, se presentan los resultados obtenidos para los valores de K entre 1 y 29. Para que la tabla no resulte demasiado extensa, se muestran únicamente las métricas de comprobación, ya que en entrenamiento tanto el *Accuracy* como la *Precision* fueron iguales a 1,00 para todos los valores de K. Esto refleja que el modelo memoriza muy bien los datos de entrenamiento, por lo que la elección del hiperparámetro debe realizarse observando principalmente el desempeño sobre el conjunto de test.

K	Accuracy test	Precision test	K	Accuracy test	Precision test
1	0,61	0,38	16	0,69	0,52
2	0,61	0,38	17	0,68	0,50
3	0,64	0,42	18	0,68	0,51
4	0,64	0,41	19	0,68	0,51
5	0,66	0,43	20	0,69	0,53
6	0,66	0,45	21	0,69	0,53
7	0,67	0,46	22	0,69	0,55
8	0,67	0,46	23	0,69	0,54
9	0,67	0,46	24	0,69	0,56
10	0,67	0,47	25	0,69	0,54
11	0,68	0,48	26	0,69	0,56
12	0,68	0,50	27	0,69	0,56
13	0,68	0,49	28	0,69	0,56
14	0,68	0,50	29	0,69	0,56
15	0,68	0,48			

Table 16: Comparación de Accuracy y Precision en test para distintos valores de K.

A partir de estos resultados, se decidió utilizar $K = 24$, ya que presenta el valor mas alto de *Accuracy* y el mayor valor de *Precision* observado en el conjunto de comprobación, con 0,56, y al mismo tiempo alcanza uno de los mejores valores de *Accuracy*, con 0,69. Si bien los valores de K entre 26 y 29 obtienen métricas equivalentes, se optó por $K = 24$ por ser el menor valor que alcanza dicho rendimiento, favoreciendo una configuración más simple del modelo.

4.4.3 Resultados obtenidos

Dado que KNN es un algoritmo de aprendizaje perezoso que memoriza los datos de entrenamiento, las métricas de entrenamiento no aportan valor diferencial al análisis: para todos los valores de K evaluados se obtuvo 1,00 tanto en *Accuracy* como en *Precision*. Por esta razón, la evaluación del modelo se realiza sobre el conjunto de comprobación.

A continuación, se presenta la matriz de confusión obtenida para el modelo KNN seleccionado:




Figure 36: Matriz de confusión del modelo KNN seleccionado en el conjunto de comprobación.

En la matriz se observa que el modelo clasifica correctamente una gran cantidad de vuelos sin demora, pero todavía presenta dificultades para identificar los vuelos demorados. En particular, se registran pocos falsos positivos en comparación con configuraciones de K más bajas, lo cual es coherente con el criterio de priorizar la *Precision*; sin embargo, también se observa una cantidad importante de falsos negativos.

De este modo, con $K = 24$, el modelo KNN alcanzó un *Accuracy* de 69% y una *Precision* de 56% en comprobación. Si bien el aumento de K permitió mejorar progresivamente la *Precision* respecto de los primeros valores evaluados, el desempeño continúa siendo inferior al obtenido por los árboles de decisión para el criterio de evaluación definido. Por lo tanto, KNN no resulta el modelo más conveniente para el caso de estudio, aunque evidencia una mejora sostenida a medida que aumenta la cantidad de vecinos considerados.

4.5 Análisis discriminante

4.5.1 Preparación específica para el modelo

Para la correcta aplicación del Análisis Discriminante, se requiere trabajar exclusivamente con variables predictoras de naturaleza cuantitativa. El análisis asume que estas variables siguen una distribución normal multivariada en cada uno de los grupos definidos por la variable objetivo. Por este motivo, realizamos la siguiente preparación del dataset:

- Se incluyeron únicamente las variables numéricas clave de la vista minable: *ocupacion_vuelo*, *visibilidad* y *tiempo_estimado_vuelo* excluyendo *puerta_embarque* ya que aunque sea una variable numerica es mas una variable identificadora mas que una característica descriptiva, ademas, como podemos ver en el analisis univariable la variable es practicamente uniforme por lo que no va a seguir el supuesto de normalidad.
- Las variables *condiciones_climaticas*, *congestion_aerea* o *tipo_fuselaje* fueron excluidas de este modelo. Forzar su inclusión violaría de forma crítica el supuesto de normalidad multivariada.
- Se mantuvo la decisión de descartar *distancia_vuelo* y conservar *tiempo_estimado_vuelo*, protegiendo la estabilidad del cálculo de la matriz de covarianza inversa.

4.5.2 Supuestos

Supuesto 1: Normalidad de las variables

Al realizar la prueba de normalidad de las variables, podemos observar que las significancia de todas ellas es menor a 0.05, lo cual nos lleva a rechazar la hipótesis nula de normalidad de las variables. Por esto, el supuesto no lo pasa, sin embargo vamos a continuar con el análisis aunque el modelo tendrá un menor sustento estadístico.

Pruebas de normalidad			
	Kolmogorov-Smirnov ^a		
	Estadístico	gl	Sig.
visibilidad	,061	12043	,000
ocupacion_vuelo	,057	12043	,000
tiempo_estimado_vuelo	,214	12043	,000

a. Corrección de significación de Lilliefors

Figure 37: Pruebas de normalidad realizadas.

Además, se presetan los gráficos Q-Q de las variables utilizadas, en donde claramente se puede ver que todas se desvían de sus respectivas rectas, confirmando la no normalidad de las mismas.




Figure 38: Q-Q ocupacion_vuelos




Figure 39: Q-Q tiempo_estimado_vuelo.




Figure 40: Q-Q visibilidad.

Supuesto 2: No multicolinealidad

Diagnósticos de colinealidad^a

Modelo	Dimensión	Autovalor	Índice de condición	(Constante)	Proporciones de varianza		
					tiempo_estimado_vuelo	visibilidad	ocupacion_vuelo
1	1	3,374	1,000	,00	,03	,02	,00
	2	,434	2,787	,00	,91	,07	,00
	3	,169	4,467	,03	,05	,87	,06
	4	,023	12,084	,96	,01	,04	,93

a. Variable dependiente: demora

Figure 41: Diagnóstico multicolinealidad.

Para evaluar la multicolinealidad tendremos que analizar la columna índice de condición, que nos dice que si su ultimo valor excede al valor 30 tendríamos multicolinealidad. Al observar los resultados arrojados por la tabala "Diagnostico de colinealidad" podemos ver que el último valor es menor a 30, por lo tanto podemos afirmar que el supuesto se cumple y hay ausencia de multicolinealidad.

Supuesto 3: Matrices de varianza y covarianza iguales

En primera instancia, se realizó la prueba de M de box, donde se puede claramente observar que la significancia es 0, lo cual es menor a 0.05 y por lo tanto se rechaza la hipótesis nula, por lo que no pasa el supuesto de la igualdad de las matrices de varianza y covarianza.

Resultados de prueba		
M de Box		67,596
F	Aprox.	11,262
	gl1	6
	gl2	384195967,1
	Sig.	,000
Prueba la hipótesis nula de las matrices de covarianzas de población iguales.		

Figure 42: M de box

4.5.3 Resultados obtenidos

Continuando con el análisis, podemos observar en la tabla debajo que la significancia en el Lambda de Wilks es 0, siendo este valor menor a 0.05. De este modo, podemos decir que la función discriminante es estadísticamente significativa y que la separación entre grupos no se debe al azar.

Lambda de Wilks				
Prueba de funciones	Lambda de Wilks	Chi-cuadrado	gl	Sig.
1	,982	213,499	3	,000

Figure 43: Lambda de Wilks

Si bien hay dos supuestos que no se cumplen, decidimos realizar el modelo sabiendo que el mismo va a estar lejos de ser óptimo. De este modo, la matriz de confusión resultante fue la siguiente:

Resultados de clasificación^a

		Pertenencia a grupos pronosticada			
		demora	0	1	Total
Original	Recuento	0	4520	3659	8179
		1	1765	2099	3864
	%	0	55,3	44,7	100,0
		1	45,7	54,3	100,0

a. 55,0% de casos agrupados originales clasificados correctamente.

Figure 44: Matriz de confusión del análisis discriminante datos entrenamiento.

A partir de la matriz de confusión del análisis discriminante, considerando como clase positiva a los vuelos con demora, se observa que el modelo clasificó correctamente 4520 vuelos sin demora y 2099 vuelos con demora. En cambio, clasificó incorrectamente 3659 vuelos sin demora como demorados y 1765 vuelos demorados como no demorados.

El *Accuracy* para entrenamiento es:

$$Accuracy = \frac{4520 + 2099}{12043} = 0,549 = 54,9\%$$

La *Precision* para entrenamiento es:

$$Precision = \frac{2099}{2099 + 3659} = 0,3645 = 36,45\%$$

Resultados de clasificación^a

		Pertenencia a grupos pronosticada			
		demora	0	1	Total
Original	Recuento	0	1128	915	2043
		1	419	495	914
	%	0	55,2	44,8	100,0
		1	45,8	54,2	100,0

a. 54,9% de casos agrupados originales clasificados correctamente.

Figure 45: Matriz de confusión del análisis discriminante datos validación.

El *Accuracy* para comprobación es:

$$Accuracy = \frac{1128 + 495}{2957} = 0,549 = 54,9\%$$

La *Precision* para comprobación es:

$$Precision = \frac{495}{495 + 915} = 0,3511 = 35,11\%$$

Los resultados de entrenamiento y comprobación son prácticamente iguales, lo cual indica que el modelo no está sobreajustado.

Estos resultados indican que el análisis discriminante logra clasificar correctamente el 54,9% de los casos totales con una precisión de 35,11%. Si bien el desempeño es superior a una clasificación completamente aleatoria, el nivel de acierto y precisión obtenida son moderados, por lo que el modelo presenta una capacidad limitada para anticipar demoras en comparación con otros modelos evaluados. Esto era esperable, dado que hay dos supuestos que no se cumplen.

4.6 Regresión logística

4.6.1 Preparación específica para el modelo

El modelo de regresión logística corresponde a una técnica de clasificación supervisada que se utiliza generalmente cuando la variable objetivo presenta categorías discretas, especialmente binarias. En nuestro caso de estudio, se utilizó este modelo porque puede resultar una opción fructífera para analizar la probabilidad de demora de los vuelos.

Para la preparación de los datos se utilizó la vista minable construida en las etapas anteriores. El modelo se aplicó considerando como variable objetivo a *demora*, y se la comparó contra las variables *condiciones_climaticas*, *visibilidad*, *congestion_aerea*, *ocupacion_vuelo*, *pais_destino*, *pais_origen*, *dia_semana* y *franja_horaria*.

Para este modelo no fue necesario eliminar variables categóricas ni transformarlas manualmente. Esto se debe a que la herramienta utilizada selecciona las variables indicadas y convierte automáticamente las variables categóricas en variables numéricas a través de one-hot encoding, permitiendo incorporarlas al modelo de regresión logística.

Inicialmente contabamos con más de 60 variables en ecuación, de las cuales muchas presentaban una significancia mayor al 0.05 en la tabla Variables en Ecuación, lo que indica que esas variables no aportaban información significativa respecto a otras, por ello realizamos el procedimiento de ir eliminando las variables una por una (la de mayor significancia), siempre que estas excedían ese valor. De este modo, tan solo nos quedamos con *temporada_alta*, *visibilidad*, *dia_viernes*, *clima_nublado*, *clima_lluvia*, *clima_tormenta*, *cong_media*, *cong_alta*, *por_eeuu*, *por_panama* y *por_espana*. Para referencia, por es país de origen y cong es congestión.

Variables en la ecuación							
		B	Error estándar	Wald	gl	Sig.	Exp(B)
Paso 1 ^a	temporada_alta	,463	,042	119,442	1	,000	1,589
	visibilidad	-,015	,003	31,093	1	,000	,985
	dia_viernes	,154	,055	7,724	1	,005	1,167
	clima_nublado	-,191	,052	13,263	1	,000	,826
	clima_lluvia	,356	,058	37,398	1	,000	1,428
	clima_tormenta	1,303	,082	251,136	1	,000	3,681
	cong_media	,475	,048	99,454	1	,000	1,608
	cong_alta	1,141	,055	429,438	1	,000	3,131
	por_eeuu	,275	,089	9,573	1	,002	1,316
	por_panama	-,191	,076	6,346	1	,012	,826
	por_espana	,440	,191	5,307	1	,021	1,553
	Constante	-1,302	,061	455,365	1	,000	,272

a. Variables especificadas en el paso 1: temporada_alta, visibilidad, dia_viernes, clima_nublado, clima_lluvia, clima_tormenta, cong_media, cong_alta, por_eeuu, por_panama, por_espana.

Figure 46: Variables en ecuación

De este modo al realizar la prueba Ómnibus, pudimos observar que la significancia en modelo es menor a 0.05. Esto indica que las variables independientes explican de forma conjunta a la variable dependiente(demora).

Pruebas ómnibus de coeficientes de modelo				
		Chi-cuadrado	gl	Sig.
Paso 1	Paso	1090,390	11	,000
	Bloque	1090,390	11	,000
	Modelo	1090,390	11	,000

Figure 47: Prueba Omnibus

4.6.2 Supuestos

Supuesto 1: Errores centrados

Para este punto pudimos verificar que el rango 95% de intervalo de confianza de la diferencia va de -0.007 a 0.007, lo cual incluye el 0, e indica que la media de los errores es igual a 0, por lo que este supuesto se cumple.

Prueba para una muestra						
Valor de prueba = 0						
	t	gl	Sig. (bilateral)	Diferencia de medias	95% de intervalo de confianza de la diferencia	
					Inferior	Superior
Diferencia entre las probabilidades pronosticadas y observadas	,000	11899	1,000	,00000000	-,0079983	,0079983

Figure 48: Prueba T para una muestra

Supuesto 2: Homocedasticidad

Para este punto fue necesario dividir el set de datos en tres grupos de igual tamaño (de 3966 registros cada uno). Luego, al realizar la prueba de homocedsticidad sobre estos grupos, en la fila 'Se basa en la media', el valor de la significancia es mayor a 0.05, lo cual indica que no se rechaza la hipótesis nula y los errores son homocedásticos, por lo que el supuesto se cumple.

Prueba de homogeneidad de varianzas					
		Estadístico de Levene	gl1	gl2	Sig.
Diferencia entre las probabilidades pronosticadas y observadas	Se basa en la media	1,470	2	11897	,230
	Se basa en la mediana	,437	2	11897	,646
	Se basa en la mediana y con gl ajustado	,437	2	11895,854	,646
	Se basa en la media recortada	1,587	2	11897	,205

Figure 49: Prueba homocedasticidad

Supuesto 3: Distribución normal de los errores

Al realizar la prueba de normalidad de Kolmogorov-Smirnov (dado que $N > 50$), podemos observar que la significancia dio 0, lo cual es menor a 0.05. De este modo se rechaza la hipótesis nula, por lo que los errores no siguen una distribución normal. Esto no invalida el modelo, por lo que vamos a seguir con el análisis.

Pruebas de normalidad

	Kolmogorov-Smirnov ^a		
	Estadístico	gl	Sig.
Diferencia entre las probabilidades pronosticadas y observadas	,287	11900	,000

a. Corrección de significación de Lilliefors

Figure 50: Prueba normalidad

Esta misma situación se evidencia en el gráfico Q-Q, que claramente no sigue el recorrido de la recta.




Figure 51: Gráfico Q-Q

Supuesto 4: No Multicolinealidad

En la tabla de abajo, podemos observar que el índice de condición es de 6.885, claramente menor a 30. Esto indica que no hay multicolinealidad, y por ende este supuesto lo pasa.

Diagnósticos de colinealidad ^a															
Modelo	Dimensión	Autovalor	Índice de condición	Proporciones de varianza											
				(Constante)	temporada_alta	visibilidad	dia_viernes	clima_nublado	clima_luvia	clima_tormenta	cong_media	cong_alta	por_eeu	por_panama	por_espana
1	1	3,862	1,000	,01	,02	,01	,01	,01	,01	,00	,02	,01	,00	,01	,00
	2	1,047	1,920	,00	,00	,01	,00	,04	,04	,56	,00	,01	,00	,01	,01
	3	1,017	1,948	,00	,00	,00	,00	,12	,19	,00	,01	,02	,26	,19	,02
	4	1,006	1,960	,00	,00	,00	,01	,04	,05	,01	,10	,26	,00	,01	,25
	5	,999	1,967	,00	,00	,00	,00	,01	,02	,00	,04	,09	,10	,00	,63
	6	,980	1,985	,00	,00	,00	,00	,09	,20	,00	,03	,07	,24	,17	,02
	7	,857	2,123	,00	,00	,00	,39	,00	,00	,00	,00	,00	,24	,37	,03
	8	,789	2,212	,00	,09	,00	,54	,01	,01	,02	,01	,01	,13	,21	,04
	9	,600	2,537	,00	,76	,00	,02	,10	,09	,06	,02	,01	,00	,01	,00
	10	,471	2,865	,00	,05	,01	,01	,42	,29	,09	,27	,18	,00	,01	,00
	11	,292	3,639	,04	,05	,28	,01	,14	,09	,02	,41	,28	,00	,01	,00
	12	,081	6,885	,95	,04	,69	,01	,01	,01	,23	,11	,07	,01	,01	,00

a. Variable dependiente: tiempo_estimado_vuelo

Figure 52: Gráfico Multicolinealidad

Supuesto 5: No Autocorrelación de errores

Al analizar la autocorrelación de los errores, podemos observar en la tabla que todos los valores de las significancias son mayores a 0.05, lo cual indica que los errores no están correlados en ninguno de los retardos. De esta manera, este supuesto lo pasa.

Autocorrelaciones					
Serie: Diferencia entre las probabilidades pronosticadas y observadas					
Retardo	Autocorrelación	Desv. Error ^a	Estadístico de Box-Ljung		
			Valor	gl	Sig. ^b
1	-,005	,009	,242	1	,622
2	,009	,009	1,174	2	,556
3	-,008	,009	1,924	3	,588
4	,018	,009	5,639	4	,228
5	,005	,009	5,945	5	,312

a. El proceso subyacente asumido es independencia (ruido blanco).

b. Se basa en la aproximación de chi-cuadrado asintótica.

Figure 53: Tabla Autocorrelaciones Errores

Además en el gráfico de diferencias entre las probabilidades pronosticadas y observadas, podemos observar que prácticamente no hay diferencia entre las probabilidades observadas y las pronosticadas para todos los retardos.




Figure 54: Gráfico diferencia entre probabilidad pronosticada y observada.

Supuesto 6: Independencia entre variables explicativas y residuos

Para analizar este supuesto, en la tabla de correlaciones se observa que todas las significancias bilaterales de las variables son de 1 respecto a los residuos. Estos valores son claramente mayores a 0.05, lo cual indica que no hay correlación significativa entre esas variables independientes y los errores, por lo que este supuesto se cumple.

		pronosticada s y observadas
Diferencia entre las probabilidades pronosticadas y observadas	Correlación de Pearson	1
	Sig. (bilateral)	
	N	11900
temporada_alta	Correlación de Pearson	,000
	Sig. (bilateral)	1,000
	N	11900
visibilidad	Correlación de Pearson	,000
	Sig. (bilateral)	1,000
	N	11900
dia_viernes	Correlación de Pearson	,000
	Sig. (bilateral)	1,000
	N	11900
clima_nublado	Correlación de Pearson	,000
	Sig. (bilateral)	1,000
	N	11900
clima_lluvia	Correlación de Pearson	,000
	Sig. (bilateral)	1,000
	N	11900
clima_tormenta	Correlación de Pearson	,000
	Sig. (bilateral)	1,000
	N	11900
cong_media	Correlación de Pearson	,000
	Sig. (bilateral)	1,000
	N	11900
cong_alta	Correlación de Pearson	,000
	Sig. (bilateral)	1,000
	N	11900
por_eeuu	Correlación de Pearson	,000
	Sig. (bilateral)	1,000
	N	11900
por_panama	Correlación de Pearson	,000
	Sig. (bilateral)	1,000
	N	11900
por_espana	Correlación de Pearson	,000
	Sig. (bilateral)	1,000
	N	11900

Figure 55: Tabla Correlaciones

4.6.3 Resultados obtenidos

Primero, analizamos la curva ROC, que es independiente al punto de corte. Se puede observar que la línea azul(probabilidad pronosticada) está por arriba de la línea roja(línea de referencia).

Además, el AUC es de 0.680, lo cual indica que el modelo puede discriminar de manera aceptable los vuelos con demora de los vuelos sin demora.




Figure 56: Curva ROC.

En primer lugar, se observó el punto de corte de 0,5, correspondiente al valor predeterminado de la aplicación. Este primer análisis arrojó los siguientes resultados:

Tabla de clasificación^a

		Pronosticado		Porcentaje correcto
		demora 0	1	
Paso 1	Observado demora 0	7678	501	93,9
	1	3115	749	19,4
	Porcentaje global			70,0

a. El valor de corte es ,500

Figure 57: Matriz de confusión del modelo de entrenamiento de regresión logística con punto de corte 0,500.

		Pronosticado		Porcentaje correcto
		demora 0	1	
Paso 1	demora 0	1906	137	93,3
	1	710	204	22,3
	Porcentaje global			71,4

a. El valor de corte es ,500

Figure 58: Matriz de confusión del modelo de validación de regresión logística con punto de corte 0,500.

El modelo presenta una exactitud global del 70,0% para el set de entrenamiento y de 71,4% para validación, clasificando correctamente la mayoría de los vuelos sin demora. Además, la precisión para el modelo con los datos de entrenamiento fue del 59,9% y para los datos de validación se mantuvo prácticamente invariable, resultando una precisión del 59,8%.

Sin embargo, al probar con varios puntos de corte (0.6, 0.7 y 0.73), pudimos observar que a medida que subíamos este valor, la precisión también mejoraba. De esta forma y tomando como punto de corte el 0.73, para los datos de entrenamiento se obtuvo la siguiente matriz de confusión:

Tabla de clasificación^a

		Pronosticado		Porcentaje correcto
		demora 0	1	
Paso 1	demora 0	8141	38	99,5
	1	3731	133	3,4
	Porcentaje global			68,7

a. El valor de corte es ,730

Figure 59: Matriz de confusión del modelo de entrenamiento de regresión logística con punto de corte 0,73.

El modelo presenta una exactitud global del 68.7% para los datos de entrenamiento. Además, se obtuvo una *Precisión* de 77,8%.

Tabla de clasificación^a

		Pronosticado		Porcentaje correcto
		demora 0	1	
Paso 1	demora			
	0	2032	11	99,5
	1	883	31	3,4
Porcentaje global				69,8

a. El valor de corte es ,730

Figure 60: Matriz de confusión del modelo de validación de regresión logística con punto de corte 0,73.

El *Accuracy* para comprobación es:

$$Accuracy = \frac{2032 + 31}{2032 + 11 + 883 + 31} = 0,698 = 69,8\%$$

El *Precisión* para comprobación es:

$$Precisión = \frac{31}{31 + 11} = 0,738 = 73,8\%$$

Se puede observar que los valores para entrenamiento y validación son similares, lo cual indica que el modelo tiene una buena capacidad de generalización.

A diferencia del modelo anterior, se observa una mejora en la precisión, pasando esta del 59,8% al 73,8%, sin una variación considerable en el Accuracy. De este modo, el modelo consigue disminuir la cantidad de falsos positivos, lo cual planteamos como el objetivo de negocio.

5 Fase de Evaluación

5.1 Comparación final de modelos

A continuación, se comparan los modelos construidos utilizando las métricas definidas como principales para este problema: *Accuracy* y *Precision*. La comparación se realiza sobre el conjunto de comprobación, ya que permite evaluar la capacidad de generalización de cada técnica sobre datos no utilizados durante el entrenamiento.

Modelo	Accuracy	Precision
Árbol de decisión en SPSS Modeler	69,80%	71,69%
Árbol de decisión en Python	69,43%	65,85%
KNN en Python	69,00%	56,00%
Análisis Discriminante	54,9%	35,11%
Regresión logística	69,80%	73,8%

Table 17: Comparación final de Accuracy y Precision de los modelos sobre el conjunto de comprobación.

Al comparar los resultados, se observa que la regresión logística presenta el mayor valor de *Precision*, con 73,8%, y además mantiene un *Accuracy* de 69,80%, igual al obtenido por el árbol de decisión en SPSS Modeler. Esto indica que, cuando el modelo predice una demora, esa predicción resulta más confiable que en las demás técnicas evaluadas y reduce el riesgo de asignar beneficios de manera innecesaria.

El árbol de decisión en SPSS Modeler también presenta un desempeño competitivo, con 69,80% de *Accuracy* y 71,69% de *Precision*. Si bien iguala a la regresión logística en exactitud global, queda levemente por debajo en precisión, que es la métrica prioritaria para el problema de negocio.

El árbol de decisión en Python alcanza 69,43% de *Accuracy* y 65,85% de *Precision*. Aunque logra un resultado consistente, no supera a los modelos desarrollados en SPSS ni a la regresión logística bajo el criterio de penalizar falsos positivos.

KNN alcanza un *Accuracy* de 69,00% y una *Precision* de 56,00%. Si bien mantiene una exactitud global similar a otros modelos, su precisión continúa por debajo de la obtenida por la regresión logística y los árboles de decisión.

El análisis discriminante alcanza un *Accuracy* de 54,9%, con una *Precision* de 35,10%. Es el rendimiento más bajo entre los modelos comparados respecto de las métricas principales definidas.

La regresión logística presenta el mejor equilibrio para el objetivo definido: iguala el mayor *Accuracy* observado, con 69,80%, y supera al árbol de decisión en SPSS Modeler en *Precision*, alcanzando 73,8%. Por este motivo, se considera la alternativa más conveniente cuando se busca que las predicciones positivas de demora sean lo más confiables posible.

Además, a esta evaluación mediante el uso de métricas importantes, vamos a complementarla con la construcción de una matriz de costos, de forma que se puedan calcular los costos que se generan al predecir demoras correctamente, incorrectamente y demás variantes. Concluimos que en este caso la predicción más costosa será el Falso Positivo (FP): el modelo predice que el vuelo se demorará, pero en realidad no se demora. Este error genera la asignación innecesaria de beneficios, como vouchers o accesos VIP, provocando costos evitables para la empresa. Luego, sigue el Falso Negativo (FN): el modelo predice que el vuelo no se demorará, pero en realidad sí se demora. Ante estas observaciones, establecemos los costos de la siguiente manera:

Costos asociados	No predijo demora	Predijo demora
No hubo demora	0 (TN)	50 u.m. (FP)
Hubo demora	5 u.m. (FN)	0 (TP)

Table 18: Matriz de costos

Realizando las operaciones pertinentes sobre los resultados de las matrices de confusión sobre los datos de validación de cada modelo, se obtienen los siguientes costos asociados:

Modelo	Costos incurridos
Árbol en Modeler	$50 \cdot 47 + 5 \cdot 850 = 6.600$ u.m.
Árbol en Python	$50 \cdot 42 + 5 \cdot 875 = 6.475$ u.m.
KNN en Python	$50 \cdot 111 + 5 \cdot 817 = 9.635$ u.m.
Análisis Discriminante	$50 \cdot 915 + 5 \cdot 419 = 47.845$ u.m.
Regresión Logística	$50 \cdot 11 + 5 \cdot 883 = 4.965$ u.m.

Table 19: Tabla de costos asociados

5.2 Selección del modelo final

Considerando el criterio definido en la fase de modelado, el modelo más conveniente para colaborar con el problema de negocio de DS Airlines es la Regresión Logística, con punto de corte 0,73. Esta elección se fundamenta en que alcanza la mayor *Precision* entre los modelos comparados, con 73,8%, manteniendo al mismo tiempo un *Accuracy* de 69,80%, igual al obtenido por el árbol de decisión en SPSS Modeler. Además, como se puede verificar en la matriz de costos, este modelo es el que menor costo supone bajo el criterio de penalizar principalmente los falsos positivos, fortaleciendo la elección.

Desde el punto de vista del negocio, este modelo permite asignar beneficios de forma más eficiente, ya que reduce la cantidad de vuelos clasificados como demorados cuando en realidad no lo están. Si bien esta configuración puede dejar sin detectar algunas demoras, resulta más adecuada para el objetivo planteado, porque prioriza que las alertas positivas sean confiables y evita malgastar recursos en pasajeros cuyos vuelos finalmente no presentan demora.

6 Fase de Entendimiento de los Datos de Clientes

6.1 Descripción de los datos (tipo de variable, valores posibles)

Basándonos en el archivo *clientes.xls*, analizaremos las variables disponibles, descartando primariamente variables como *id_cliente*, ya que no son relevantes y no aportan valor de utilidad para el

análisis objetivo.

A continuación, se describen las variables de la base de datos de clientes, teniendo en cuenta su tipo y sus posibles valores.

Variable	Tipo	Valores posibles
<i>sexo</i>	Categórica	M, F, No binario
<i>provincia</i>	Categórica	Salta, Córdoba, entre otras.
<i>edad</i>	Numérica Discreta	[18; 80]
<i>ocupacion</i>	Categórica	Médico, Docente, entre otras.
<i>cant_vuelos</i>	Numérica Discreta	[1; 99]
<i>clase_preferida</i>	Categórica	Económica, Ejecutiva, Primera Clase
<i>gasto_acumulado</i>	Numérica Continua	[71.25; 253,140.32]
<i>gasto_acumulado_extra</i>	Numérica Continua	[3.21; 47,394.97]
<i>programaMillas</i>	Binaria	Si, No
<i>cantidad_millas</i>	Numérica Discreta	[0; 541,589]
<i>ingreso_mensual</i>	Numérica Discreta	[300; 350,000]
<i>anticipacion_compra_promedio</i>	Numérica discreta	[0; 180]
<i>canal_compra</i>	Categórica	Agencia, App, Aeropuerto, Web

Table 20: Descripción de las variables de la base de datos de clientes.

6.2 Análisis exploratorio

6.2.1 Análisis univariante

Variables numéricas A continuación, se presentan los gráficos y los estadísticos correspondientes al análisis univariante de las variables numéricas de la base de clientes.

Variable Edad

Estadístico	Valor
<i>Media</i>	37.8
<i>Desvío</i>	11.4
<i>Min</i>	18
<i>1er Cuartil</i>	29
<i>2do Cuartil</i>	38
<i>3er Cuartil</i>	46
<i>Max</i>	80

Table 21: Estadísticos edad.




Figure 61: Distribución de clientes por edad.

El histograma de *edad* muestra que el rango etario se encuentra entre los 18 y los 80 años. El pico de clientes se encuentra a los 18 años con aproximadamente 2700 clientes. La media se encuentra cercana a los 38 años.

Variable *cant_vuelos*

Estadístico	Valor
<i>Media</i>	17.1
<i>Desvío</i>	15.7
<i>Min</i>	1
<i>1er Cuartil</i>	6
<i>2do Cuartil</i>	14
<i>3er Cuartil</i>	21
<i>Max</i>	99

Table 22: Estadísticos *cant_vuelos*




Figure 62: Distribución de la variable *cant_vuelos* por cliente.

En cuanto a la variable *cant_vuelos*, se observa que la amplia mayoría de clientes realizaron entre 1 y 22 vuelos, acumulándose el 75% de los clientes hasta los 21 vuelos. Podemos observar que el

valor máximo es bastante superior a la media(99 vuelos).

Variable gasto_acumulado

Estadístico	Valor
<i>Media</i>	6587.5
<i>Desvío</i>	12439.8
<i>Min</i>	71.2
<i>1er Cuartil</i>	1404.5
<i>2do Cuartil</i>	3099.8
<i>3er Cuartil</i>	6317.3
<i>Max</i>	253140.3

Table 23: Estadísticos gasto_acumulado




Figure 63: Distribución de la variable gasto_acumulado.

Respecto al histograma de *gasto_acumulado*, se observa que la gran mayoría de los clientes gastaron menos de 10000 USD. Sin embargo, algunos clientes presentan gastos acumulados mucho mayores, llegando hasta los 250000 USD en los casos extremos.

Variable gasto_acumulado_extra

Estadístico	Valor
<i>Media</i>	953.7
<i>Desvío</i>	1987.6
<i>Min</i>	3.2
<i>1er Cuartil</i>	167.4
<i>2do Cuartil</i>	403.2
<i>3er Cuartil</i>	912.5
<i>Max</i>	47394.9

Table 24: Estadísticos gasto_acumulado_extra




Figure 64: Distribución de la variable `gasto_acumulado_extra`.

La variable `gasto_acumulado_extra` está muy concentrada cerca de 0, lo que indica que la mayoría de los casos casi no presentan gasto extra, mientras que unos pocos alcanzan valores muy altos de hasta casi 48000.

Variable `cantidad_millas`

Estadístico	Valor
<i>Media</i>	6759.3
<i>Desvío</i>	23529.6
<i>Min</i>	0
<i>1er Cuartil</i>	0
<i>2do Cuartil</i>	0
<i>3er Cuartil</i>	0
<i>Max</i>	541589

Table 25: Estadísticos `cantidad_millas`




Figure 65: Distribución de la variable `cantidad_millas`.

La variable `cantidad_millas` indica que la gran mayoría de los clientes no tienen millas acumuladas, ya que las 0 millas acumulan el 75% de clientes. Los clientes que sí tienen millas llegan hasta las

500.000 en su caso más extremo.

Variable ingreso_mensual

Estadístico	Valor
<i>Media</i>	3062.8
<i>Desvío</i>	3780.3
<i>Min</i>	300
<i>1er Cuartil</i>	1250
<i>2do Cuartil</i>	2100
<i>3er Cuartil</i>	3823
<i>Max</i>	350075

Table 26: Estadísticos ingreso_mensual




Figure 66: Distribución de la variable ingreso_mensual.

El gráfico de *ingreso_mensual* exhibe una acumulación en lado izquierdo. El pico muy alto cerca del valor 0 indica que la mayor parte de la población analizada tiene ingresos mensuales bajos en comparación con el rango total. Esto se puede confirmar con el valor del tercer cuartil que indica que el 75% de los clientes tienen ingresos de hasta 3823 USD.

Variable anticipacion_compra_promedio

Estadístico	Valor
<i>Media</i>	19.9
<i>Desvío</i>	21.4
<i>Min</i>	0
<i>1er Cuartil</i>	5
<i>2do Cuartil</i>	13
<i>3er Cuartil</i>	27
<i>Max</i>	180

Table 27: Estadísticos anticipacion_compra_promedio




Figure 67: Distribución de la variable anticipacion_compra_promedio.

Al analizar la variable *anticipacion_compra_promedio*, se evidencia que la mayoría de los clientes sacan los pasajes entre 0 y 25 días antes de la salida del vuelo, encontrándose el mayor pico en 0 días. Es una distribución altamente sesgada a la derecha.

Variables categóricas A continuación, se presentan los gráficos correspondientes al análisis univariante de las variables categóricas de la base de clientes.




Figure 68: Distribución de clientes por sexo.

En el gráfico de distribución de clientes por sexo se observa un claro equilibrio entre la cantidad de pasajeros mujeres y hombres. En comparación, muy pocos pasajeros se identifican con sexo no binario.




Figure 69: Distribución de clientes por ocupación.

En la distribución por ocupación se nota una clara mayoría de personas empleadas. Entre profesionales independientes y docentes se ubica el segundo grupo más grande. Luego aparecen estudiantes,

ejecutivos y comerciantes, con valores entre 3400 y 3600 aproximadamente. La categoría con menor cantidad de personas es jubilados.




Figure 70: Distribución de clientes por clase preferida.

A partir del gráfico se observa que aproximadamente el 74% de los clientes prefieren viajar en clase económica, alrededor del 21% viaja en clase ejecutiva y menos del 5% prefiere viajar en primera clase.




Figure 71: Distribución de clientes por programa de millas.

La distribución de clientes por programa de millas muestra una diferencia significativa: 38052 clientes no forman parte del programa, mientras que 11948 clientes sí están adheridos.




Figure 72: Distribución de clientes por canal de compra.

Web y App son los canales dominantes, con 19743 y 18514 clientes respectivamente, manteniéndose muy parejos entre sí. Agencia queda bastante más abajo con 7300 clientes y Aeropuerto es el canal menos usado con 4443. Se observa que la mayoría de los clientes prefiere los canales digitales, que juntos suman más del 75% del total.




Figure 73: Distribución de clientes por país de residencia.

Argentina concentra la mayor parte de los clientes con 23509, casi el doble que Colombia, que queda segunda con 12527. Brasil cuenta con 8191 clientes y Panamá es el país con menor cantidad, con 5773. La distribución está desbalanceada, ya que Argentina representa casi la mitad del total de clientes, lo cual puede influir en el modelo si no se considera este desbalance entre países.

6.2.2 Análisis multivariante




Figure 74: Gráfico ingreso mensual por ocupación y clase preferida

Como se observa en el gráfico, aunque los empleados son nuestro volumen de clientes más alto, su capacidad económica parece limitada, ya que ninguno registra viajes en primera clase. Por otro lado, queda claro que el público objetivo para la categoría primera clase está compuesto principalmente por ejecutivos y empresarios, quienes lideran este segmento.




Figure 75: Gráfico de relación entre gasto acumulado y cantidad de millas

En este gráfico se identifica una tendencia lineal positiva muy clara para el grupo de clientes afiliados al programa de millas. El comportamiento de los datos confirma que a mayor nivel de consumo o gasto, mayor es la acumulación de millas, validando la efectividad del programa para este segmento.




Figure 76: Gráfico de la edad promedio según clase y sexo

Al revisar la distribución por edad y género, encontramos dos puntos clave: primero, no se registran clientes de la tercera edad en primera clase; y segundo, el comportamiento de compra entre hombres y mujeres según su edad es prácticamente idéntico. Un dato demográfico interesante a tener en cuenta es que el segmento no binario dentro de esta base de datos presenta un perfil significativamente más joven.




Figure 77: Gráfico ingreso mensual por ocupación y clase preferida

Iniciamos el procesamiento de datos agrupando el dataset por provincia de origen. Encontramos que, aunque la gran mayoría de nuestros clientes son argentinos, su tasa de elección de primera clase es notablemente más baja en comparación con el exterior. A su vez, en los mercados extranjeros, a pesar de que el volumen total de clientes varía según el país, la demanda de primera clase se muestra inelástica o constante, sin grandes fluctuaciones.

6.2.3 Matriz de correlación




Figure 78: Matriz de correlación entre las variables.

En la matriz de correlación se observa una relación muy fuerte entre *gasto_acumulado* y *gasto_acumulado_extra*, lo cual resulta coherente, ya que aquellos clientes que mas gastaron son quienes disponen de mas dinero para hacer gastos extra. Estas variables se relacionan tambien con *cant_millas* y *cant_vuelos* lo cual sigue la misma logica, quienes mas hayan viajado mas van a haber gastado.

6.2.4 Matriz de covarianza




Figure 79: Matriz de covarianza de las variables numéricas de clientes.

La matriz de covarianza revela que las relaciones lineales más fuertes del dataset se concentran entre las variables de actividad y gasto del cliente. Las covarianzas más elevadas se observan entre *gasto_acumulado* y *gasto_acumulado_extra*, con un valor aproximado de $2,2 \times 10^7$, y entre *gasto_acumulado* y *cantidad_millas*, con un valor aproximado de $1,63 \times 10^8$. Esto indica que estas variables tienden a crecer conjuntamente: a mayor gasto en vuelos, mayor acumulación de millas y mayor gasto en servicios extra.

La variable *cant_vuelos* también presenta covarianzas positivas significativas con ambas variables de gasto y con *cantidad_millas*, confirmando que la frecuencia de vuelo es un factor central del comportamiento de consumo de los clientes. Por otro lado, *anticipacion_compra_promedio* es la única variable que presenta covarianza negativa con todas las demás, lo que sugiere que los clientes

que más gastan, vuelan y acumulan millas tienden a comprar sus pasajes con menor anticipación, posiblemente por tratarse de viajeros frecuentes o de negocio con compras de último momento.

Finalmente, la variable *edad* muestra covarianzas positivas, pero de magnitudes comparativamente bajas con el resto de las variables. Esto indica que la edad por sí sola no parece ser un predictor fuerte del nivel de gasto o actividad del cliente. Cabe destacar que las diferencias de magnitud entre covarianzas se deben en gran parte a las escalas de las variables, por ejemplo millas en cientos de miles frente a edad en decenas, por lo que para comparar la fuerza real de las relaciones resulta conveniente complementar este análisis con la matriz de correlación de Pearson que se realizó anteriormente.

6.3 Evaluación de la calidad de los datos

6.3.1 Outliers

Tomando nuevamente como criterio usado en vuelos, se consideran outliers a aquellos valores que quedan por fuera de los bigotes en el gráfico de caja y bigotes de las variables numéricas.

Empezando por la *Edad*, podemos observar que todos los pasajeros tienen entre 18 a 80 años, lo cual consideramos que es una situación normal en cualquiera de los casos. De este modo, decidimos no descartar ninguno de estos valores.

Siguiendo con *cant_vuelos*, decidimos inspeccionar los casos más extremos (90 vuelos o más) y como se observa en la tabla debajo detectamos que se presentaban casos llamativos en donde el ingreso mensual no se condecía con la cantidad de vuelos realizados y el gasto acumulado. Sin embargo, se puede observar que todos estos pasajeros son deportistas por lo que asumimos que los vuelos de los mismos fueron financiados. Esto nos lleva a no descartar estos valores que en primera instancia parecían atípicos.

cant_vuelos	ingreso_mensual	ocupacion	gasto_acumulado
94	300	Deportista	8622.38
92	378	Deportista	15607.90
94	300	Deportista	12940.24
96	357	Deportista	25790.34
91	300	Deportista	24602.38
94	300	Deportista	20118.39

Table 28: Casos extremos de clientes deportistas según cantidad de vuelos, ingreso mensual y gasto acumulado.

En *gasto_acumulado* y *gasto_acumulado_extra* podemos observar que los valores más extremos para esta variable corresponden a Ejecutivos o deportistas con más de 70 vuelos. De este modo, consideramos que estos valores son normales y no los vamos a descartar.

cant_vuelos	ingreso_mensual	ocupacion	gasto_acumulado	gasto_acumulado_extra
75	11166	Ejecutivo	183467.55	12460.42
79	11507	Ejecutivo	198994.66	10258.81
79	4520	Deportista	198720.17	40828.66
90	7411	Deportista	206031.16	33147.15
89	28612	Deportista	190482.83	24329.21
98	6141	Deportista	253140.32	40232.68
73	10866	Ejecutivo	180501.65	36194.33
79	14315	Deportista	185024.63	18948.36
88	15213	Deportista	200780.27	25768.03
85	16154	Deportista	186259.20	39061.55
79	8498	Ejecutivo	191085.43	47394.97
78	7778	Deportista	193499.52	35256.58

Table 29: Casos extremos con alto gasto acumulado y gasto acumulado extra según cantidad de vuelos, ingreso mensual y ocupación.

Para el caso de *cantidad_millas*, si bien un valor tan alto como 541589 millas podría ser imposible en muchas aerolíneas donde las mismas suelen tener un tiempo de expiración, en este caso al no tener las reglas de negocio necesarias para extraer dicha información, no vamos a descartar este valor ni otros con resultados igualmente altos.

Para *ingreso_mensual*, detectamos que los dos valores más alejados correspondían a deportistas. Esto tiene sentido ya que algunos deportistas exitosos tienen salarios extremadamente altos.

ingreso_mensual	ocupacion
350075	Deportista
229627	Deportista

Table 30: Casos extremos de ingreso mensual según ocupación.

Por último, no consideramos que ningún valor de *anticipacion_compra_promedio* deba ser descartado, dado que los pasajes de vuelo se pueden sacar tanto en el mismo día como con casi un año de anticipación.

6.3.2 Valores Faltantes

Al analizar el set de datos, podemos observar en la tabla debajo que no hay valores nulos en ninguna de las variables.

Variable	Cantidad de valores no nulos
sexo	50000
provincia	50000
edad	50000
ocupacion	50000
cant_vuelos	50000
clase_preferida	50000
gasto_acumulado	50000
gasto_acumulado_extra	50000
programaMillas	50000
cantidad_millas	50000
ingreso_mensual	50000
anticipacion_compra_promedio	50000
canal_compra	50000

Table 31: Cantidad de valores no nulos por variable en la base de clientes.

7 Fase de Preparación de los datos

7.1 Proceso de limpieza de datos

No es necesario realizar ninguna limpieza de datos dado que decidimos mantener todos los valores considerados outliers y no se detectaron valores nulos ni erróneos.

7.2 Especificación de transformaciones realizadas

Dentro de las transformaciones, decidimos agrupar las provincias por países dado que de lo contrario, se generaba mucho ruido y había demasiados valores posibles.

7.3 Especificación de la vista minable

Luego de realizar la transformación especificada, la vista minable quedó de la siguiente manera:

Número	Variable	Tipo de dato
1	sexo	Categórica
2	edad	Numérica Discreta
3	ocupacion	Categórica
4	cant_vuelos	Numérica Discreta
5	clase_preferida	Categórica
6	gasto_acumulado	Numérica Continua
7	gasto_acumulado_extra	Numérica Continua
8	programaMillas	Binaria
9	cantidad_millas	Numérica Discreta
10	ingreso_mensual	Numérica Discreta
11	anticipacion_compra_promedio	Numérica Discreta
12	canal_compra	Categórica
13	pais_origen	Categórica

Table 32: Variables y tipos de dato de la vista minable de clientes.

8 Fase de Modelado de Clientes

8.1 Estrategia general de análisis descriptivo

En esta etapa el enfoque cambia respecto al modelado de vuelos. Mientras que en el caso anterior se trabajó con técnicas supervisadas para predecir la variable *demora*, en la base de clientes se propone un análisis no supervisado orientado a la segmentación. El objetivo principal es identificar grupos de clientes con comportamientos similares, sin partir de una variable objetivo previamente definida.

Para ello se utilizarán tres técnicas de clustering y un análisis de reducción de dimensionalidad. En primer lugar, el clustering jerárquico permitirá analizar la estructura de agrupamiento mediante dendrogramas y observar posibles cortes para definir segmentos. Luego, K-Medias permitirá construir segmentos compactos a partir de variables numéricas estandarizadas y comparar si los grupos obtenidos coinciden con la estructura jerárquica previa. En tercer lugar, el cluster bietápico permitirá incorporar variables categóricas además de numéricas, lo cual resulta especialmente útil para incluir información como *sexo*, *ocupacion*, *clase_preferida*, *programaMillas*, *canal_compra* y *pais_origen*. Finalmente, el Análisis de Componentes Principales (ACP) se utilizará como técnica complementaria para reducir dimensionalidad, interpretar patrones latentes y tratar la multicolinealidad detectada entre variables de gasto, actividad y millas.

Es importante destacar que no se trabajará con toda la base de datos de cliente para realizar clustering, sino que utilizaremos únicamente a aquellos clientes que estén en vuelos que hayamos predicho como demorados, dando un total de 5466 clientes.

8.2 Cluster Jerárquico (SPSS Modeler / Python)

8.2.1 Preparación específica para el modelo

Para el clustering jerárquico se utilizaron todas las variables numéricas disponibles en la vista minable de clientes. Las variables consideradas fueron *edad*, *cant_vuelos*, *gasto_acumulado*, *gasto_acumulado_extra*, *cantidad_millas*, *ingreso_mensual* y *anticipacion_compra_promedio*.

Como estas variables presentan escalas muy diferentes, se realizó una estandarización previa. Este paso es fundamental en los modelos basados en distancia, ya que evita que variables con valores muy grandes, como *cantidad_millas* o *gasto_acumulado*, dominen la formación de los grupos por encima de variables expresadas en escalas menores, como *edad* o *anticipacion_compra_promedio*.

8.2.2 Configuración del algoritmo

Para la configuración del algoritmo se eligió el método de enlace de Ward junto con distancia euclídea. El método de Ward fue seleccionado porque busca formar grupos compactos, minimizando la variabilidad interna de los clusters en cada etapa de unión. La distancia euclídea se utilizó como medida de separación entre observaciones, ya que resulta adecuada para variables numéricas previamente estandarizadas.

El dendrograma se utilizó como herramienta principal para visualizar la estructura jerárquica de los datos y definir el punto de corte más conveniente para la segmentación.




Figure 80: Dendrograma del cluster jerárquico de clientes.

En el dendrograma se observa cómo los clientes se van agrupando progresivamente a medida que

aumenta la distancia de unión. Las uniones que se producen a distancias bajas representan grupos de clientes con características muy similares, mientras que los saltos más altos indican la unión de grupos cada vez más diferentes entre sí.

8.2.3 Resultados obtenidos

A partir del dendrograma, se decidió establecer el punto de corte en una distancia aproximada de 100. Esta decisión se fundamenta en que, visualmente, alrededor de ese valor se observa el salto más grande de distancia antes de que se fusionen grupos claramente diferenciados. Por lo tanto, cortar el dendrograma en ese nivel permite conservar segmentos relativamente homogéneos y evita unir clusters que presentan diferencias importantes en su comportamiento.




Figure 81: Gráfico de silueta del cluster jerárquico de clientes.

El gráfico de silueta permite evaluar la calidad de la segmentación obtenida. En este caso, el coeficiente de silueta se encuentra aproximadamente en 0,534, lo cual indica una buena diferenciación entre clusters. Esto significa que, en promedio, los clientes se encuentran relativamente cerca de los miembros de su propio grupo y suficientemente separados de los clientes pertenecientes a otros grupos.

Con este punto de corte, el clustering jerárquico queda definido como una segmentación inicial de 2 grupos, respaldada por el salto observado en el dendrograma y por un coeficiente de silueta aceptable.

8.2.4 Perfilado de segmentos




Figure 82: Clusters anticipación vs Gasto acumulado.

Al cruzar la variable *Anticipacion_Compra_Promedio* con *gasto_Acumulado*, se puede apreciar que la principal diferencia entre los clusters está dada por el nivel de gasto. El cluster 2(naranja) reúne a los clientes de mayor valor económico, con gastos acumulados considerablemente superiores y una tendencia a realizar sus compras con poca anticipación. Por su parte, el cluster 1(azul) está conformado mayormente por clientes con gastos acumulados bajos, incluso cuando presentan una amplia variabilidad en la anticipación de compra. Esto sugiere que el gasto acumulado resulta una variable más discriminante entre los grupos que la anticipación de compra por sí sola.




Figure 83: Clusters cantidad millas vs gasto acumulado.

Al cruzar la variable *Cant_Millas* con *gasto_Acumulado_Extra*, se puede observar que en los valores iniciales la cantidad de millas no parece un factor determinante para diferenciar a los clusters, ya que ambos grupos se superponen. Sin embargo, se puede destacar que los miembros del cluster naranja tienen un mayor gasto acumulado extra y alcanzan topes de millas mucho más altos que los pasajeros del cluster azul.




Figure 84: Clusters edad vs ingreso mensual.

Al cruzar la variable *edad* con *Ingreso_Mensual*, se puede observar que la edad no parece un factor determinante para diferenciar a los clusters, ya que ambos grupos se superponen a lo largo de casi todo el rango etario. Sin embargo, se puede destacar que los miembros del Cluster 2 alcanzan picos de ingresos mensuales mayores y están menos concentrados en la base salarial que los pasajeros del Cluster 1.




Figure 85: Clusters ingreso mensual vs gasto acumulado.

Al cruzar la variable *Ingreso Mensual* con *gasto Acumulado*, se observa que la principal diferencia entre los clusters se encuentra en el nivel de gasto acumulado. El cluster 2 concentra a los clientes con mayores gastos acumulados, aunque presentan ingresos mensuales variados, predominando valores medios. Por su parte, el cluster 1 agrupa principalmente a clientes con gastos acumulados bajos, independientemente de su ingreso mensual. Además, no se evidencia una relación lineal entre el ingreso mensual y el gasto acumulado, ya que clientes con ingresos similares pueden presentar niveles de gasto muy diferentes.




Figure 86: Ocupación.

Al cruzar la variable *Ocupación* con los clusters, se puede observar que el Cluster 1 presenta una gran diversidad laboral, con su población muy repartida entre múltiples profesiones (donde predominan los empleados, profesionales independientes y docentes). Sin embargo, se puede destacar que los miembros del Cluster 2 tienen una concentración fuertemente marcada en perfiles específicos, siendo mayoritariamente ejecutivos, seguidos por empleados y deportistas.




Figure 87: Clase preferida.

Al cruzar la variable *Clase_Preferida* con los clusters, se puede observar que la clase Económica es una opción utilizada por ambos grupos de pasajeros. Sin embargo, se puede destacar que los miembros del Cluster 2 tienen una distribución mucho más equilibrada hacia las categorías premium (con alta participación en Ejecutiva y Primera clase), a diferencia de los pasajeros del Cluster 1, quienes eligen de forma casi exclusiva la clase Económica.

8.3 Cluster K-Medias (Python)

8.3.1 Preparación específica para el modelo

Para el modelo K-Medias se utilizó el mismo conjunto de variables numéricas ya estandarizadas: *edad*, *cant_vuelos*, *gasto_acumulado*, *gasto_acumulado_extra*, *cantidad_millas*, *ingreso_mensual* y *anticipacion_compra_promedio*. Esta preparación permite aplicar el algoritmo sobre variables comparables y evita que las diferencias de escala afecten la asignación de clientes a los centroides.

8.3.2 Configuración del algoritmo

En primer lugar, se decidió utilizar el método del codo para analizar la variación de la inercia a medida que aumenta la cantidad de clusters. Este gráfico permite observar en qué punto se produce el mayor quiebre antes de que la curva comience a estabilizarse, lo cual sirve como criterio inicial para elegir un valor de K .




Figure 88: Método del codo para K-Medias.

A partir del gráfico del codo se observó que el mayor quiebre se encontraba alrededor de $K = 5$, ya que a partir de ese punto la disminución de la inercia comienza a estabilizarse. Por este motivo, inicialmente se consideró utilizar 5 clusters. Sin embargo, esta decisión generó dudas, ya que el análisis jerárquico previo había sugerido una solución de 2 clusters a partir del corte del dendrograma.

Para evaluar otras opciones y verificar si una solución con más clusters era realmente conveniente, se decidió complementar el análisis con un gráfico de siluetas. Este gráfico permite comparar la calidad de separación de los clusters para distintos valores de K y analizar si los grupos formados son compactos y diferenciables.




Figure 89: Análisis de silueta para distintos valores de K en K-Medias.

Luego de analizar el gráfico de siluetas, se decidió cambiar la decisión inicial y optar por una solución de 2 clusters. Esta elección resulta coherente con lo observado previamente en el clustering jerárquico y permite mantener una segmentación más simple, interpretable y consistente entre ambos métodos.

8.3.3 Resultados obtenidos

Con la configuración final, el modelo K-Medias se ejecutó utilizando $K = 2$. Esta cantidad de clusters permite separar a los clientes en dos grandes grupos diferenciados según sus variables numéricas de actividad, gasto, millas, ingreso, edad y anticipación de compra.




Figure 90: Gráfico de silueta del modelo K-Medias con 2 clusters.

En la evaluación del modelo con 2 clusters se obtuvo un coeficiente de silueta aproximado de 0,6. Este valor indica una buena diferenciación entre los grupos formados, ya que los clientes tienden a estar más cerca de los miembros de su propio cluster que de los clientes pertenecientes al otro grupo. Además, al compararlo con el clustering jerárquico, cuyo valor de silueta era cercano a 0,5, se observa que K-Medias logra una separación aún mejor entre los segmentos.

La decisión de trabajar con 2 clusters se fundamenta en la combinación de los resultados obtenidos: si bien el método del codo sugería inicialmente la posibilidad de utilizar 5 clusters, el análisis de siluetas mostró que la solución de 2 clusters era más sólida y ofrecía una separación más clara.

8.4 Cluster Bietápico (SPSS Modeler / Python)

8.4.1 Preparación específica para el modelo

El cluster bietápico se diferencia de K-Medias y del clustering jerárquico porque permite trabajar con variables numéricas y categóricas simultáneamente. Esto resulta especialmente útil para la base de clientes, ya que permite incorporar información cualitativa relevante como *sexo*, *clase_preferida*, *programaMillas*, *canal_compra*, *ocupacion* y *pais-origen*.

Además de estas variables categóricas, se podrán incluir variables numéricas asociadas a actividad y gasto, como *cant_vuelos*, *gasto_acumulado*, *gasto_acumulado_extra*, *cantidad_millas*, *ingreso_mensual*

y *anticipacion_compra_promedio*. Esta combinación permitirá construir segmentos más ricos desde el punto de vista del negocio, ya que no solo agrupará clientes por nivel de consumo, sino también por características demográficas y preferencias de compra.

8.4.2 Configuración del algoritmo

La configuración del cluster bietápico considerará criterios automáticos de selección de la cantidad óptima de clusters. Además, la medida usada para este modelo fue la distancia euclidiana.

En primera instancia, decidimos ejecutar el algoritmo con todas las variables disponibles en la vista minable. De esta forma, obtuvimos los siguientes resultados:




Figure 91: Clusters Bietápico con todas las variables.

Como se puede observar, se obtuvieron unicamente dos clusters(coinidiendo tanto con K-medias como con Cluster Jerárquico). Uno de los clusters estaba conformado por casi el 27% de los clientes mientras que los clientes restantes formaban parte del otro grupo. Sin embargo, se puede evidenciar que el valor de la silueta para esta configuración era inferior a 0.2. Este valor(como lo indica el propio gráfico) se considera un mal resultado. De esta forma, decidimos fijarnos cuales variables eran menos importantes, obteniendo:




Figure 92: Importancia de variables en Cluster Bietápico con todas las variables.

Sabiendo que un valor de silueta tan bajo no es aceptable y evidenciando que edad era la variable menos influyente, decidimos quitarla y volver a ejecutar el algoritmo sin ella. De esta forma, los resultados fueron los siguientes:




Figure 94: Importancia de variables en Cluster Bietápico sin edad.

Frente a estos resultados de importancia de las variables, decidimos volver a ejecutar el algoritmo sacando la variable *canal_compra*. Para esta tercer iteración, los resultados fueron los siguientes:




Figure 95: Clusters Bietápico sin *canal_compra*.

Para esta configuración,nuevamente se identificaron dos clusters. Las proporciones entre ellos se mantuvieron similares a las dos ejecuciones anteriores, con una ligera reducción en la cantidad de pasajeros en el cluster minoritario. Además, el valor de la silueta aumentó.

Sin embargo, y tras varias iteraciones, decidimos usar *ingreso_mensual*, *gasto_acumulado*, *gasto_acumulado_extra*, *clase_preferida*, *cant_vuelos* y *ocupacion* como configuración final.

8.4.3 Resultados obtenidos

Para este último caso, los resultados obtenidos fueron los siguientes:




Figure 96: Clusters Bietápico final.

De este modo, se obtuvieron dos clusters, uno formado por el 16,8% de los pasajeros, y el otro formado por el 83,2% restante. El valor de la silueta obtenido fue de 0.45, el cual es inferior a la silueta obtenida por cluster jerárquico y K-means.

8.4.4 Perfilado de segmentos




Figure 97: Perfilado de los clusters para Bietápico.

Como se puede observar en la imagen, el clúster 1 está configurado por personas con mayor cantidad de vuelos, con preferencia por primer clase y clase ejecutiva, con un mayor gasto acumulado y gasto acumulado extra y con mayores ingresos mensuales. Quienes pertenecen al clúster 2, juntan una menor cantida de vuelos, con preferencia por clase económica, con mucho menor gasto acumulado y gasto acumulado extra, y con menores ingresos mensuales.

9 Fase de Evaluación de Clientes

9.1 Comparación de los modelos de segmentación

En esta etapa se compararán los modelos de segmentación construidos para la base de clientes. La comparación incluirá métricas cuantitativas, como el coeficiente de silueta cuando corresponda, la cantidad de clusters obtenidos, el tipo de variables admitidas por cada técnica y la interpretabilidad de los perfiles generados.

Modelo	Métrica principal	Variables admitidas	Interpretabilidad
Cluster jerárquico	Dendrograma / silueta	Numéricas	Media. El dendrograma permite visualizar la formación de los grupos, pero con un conjunto de más de 5.000 registros su interpretación se vuelve compleja y poco práctica.
K-Medias	Coeficiente de silueta	Numéricas	Alta. Los clusters pueden interpretarse mediante sus centroides y perfiles promedio. Además, obtuvo el mejor coeficiente de silueta entre los modelos evaluados.
Cluster bietápico	Silueta	Numéricas y categóricas	Alta. Permite generar perfiles de clientes utilizando simultáneamente variables numéricas y categóricas, facilitando la descripción de los segmentos obtenidos.

Table 33: Comparación preliminar de los modelos de segmentación de clientes.

9.2 Selección del modelo final y perfilado de segmentos

Frente a los resultados obtenidos en los diferentes modelos, decidimos finalmente utilizar K-means con $k = 2$. De este modo, quedaron definidos dos grupos. A continuación, se detallan las características de estos:




Figure 98: Clusters edad vs ingreso.

Al cruzar la variable *edad* con *ingreso_mensual*, se puede observar que la edad no parece un factor determinante para diferenciar a los clusters. Sin embargo, se puede destacar que los miembros del cluster 0 tienen mayores ingresos mensuales que los pasajeros del cluster 1.




Figure 99: Clusters vuelos vs gasto acumulado.

Cruzando cantidad de vuelos con gasto acumulado, se puede notar que el cluster 1 se caracteriza por realizar una menor cantidad de vuelos en promedio que el cluster 0. Además, es notorio que quienes pertenecen al cluster 0 presentan una mayor cantidad de gasto acumulado que los del otro grupo en la mayoría de los casos.




Figure 100: Clusters millas vs gasto acumulado extra.

En este gráfico de dispersión, se puede destacar que quienes son del cluster 1 tienden a tener un gasto acumulado extra mucho menor que quienes pertenecen al otro grupo. Además, los miembros del cluster 0 tienen a su nombre una mayor cantidad de millas que quienes son del cluster 1.




Figure 101: Clusters ingreso vs gasto acumulado.

Al cruzar los ingresos mensuales con el gasto acumulado, se hace aun más notoria la diferencia que hay en el gasto acumulado de los grupos. El grupo 1, se caracteriza por tener un gasto acumulado de hasta 40.000 USD en sus casos más extremos, mientras que el cluster 0 tiene gastos a partir de los 20.000 USD en la mayoría de los casos llegando hasta más de 140.000USD en algunos casos.




Figure 102: Clusters anticipación vs gasto acumulado.

Además, se puede observar una gran concentración de ambos grupos entre los 0 y los 60 días de anticipación, por lo que la anticipación de compra de los pasajes no es un factor determinantes para diferenciar a los clusters.




Figure 103: Clusters ocupación.

Al inspeccionar la variable *ocupación*, se puede observar que el cluster 0 está conformado mayormente por ejecutivos, empresarios y deportistas. En cambio, el grupo 1 presenta una gran variedad de profesiones como empleados, abogados, comerciantes, docentes, entre otros.




Figure 104: Clusters clase preferida.

Respecto a la clase preferida, quienes pertenecen al cluster 1 prefieren en su gran mayoría viajar en clase económica, mientras que en el cluster 0, las proporciones entre las 3 clases son más parejas, habiendo una ligera preferencia por clase ejecutiva.




Figure 105: Clusters plan millas.

Por último, se puede observar que los pasajeros del cluster 1 no tienen plan millas en la gran mayoría de los casos, mientras que quienes pertenecen al otro grupo, son mayormente miembros del plan millas.

De esta forma, llegamos a la siguiente conclusión:

Cluster 0

Agrupar a pasajeros con alto poder adquisitivo, con ingresos mensuales elevados, un gasto acumulado significativamente mayor al del otro grupo, mayor cantidad de vuelos realizados y una gran acumulación de millas. Este grupo está conformado principalmente por ejecutivos, empresarios y deportistas, quienes muestran una preferencia más distribuida entre las clases ejecutiva, primera clase y económica.

Cluster 1

Representa a viajeros con un perfil de menores ingresos, menor gasto acumulado, menos vuelos y escasa acumulación de millas. Este grupo presenta una mayor variación en términos ocupacionales,

incluyendo empleados, docentes, comerciantes y abogados, y muestra una marcada preferencia por la clase económica.

De este modo, en caso de darse una demora en un vuelo, quienes pertenezcan al Cluster 0 recibirán un pase para ingresar a una sala VIP, mientras que quienes pertenezcan al Cluster 1 obtendrán un Voucher de comida.

9.3 Análisis de Componentes Principales – PCA (Python)

Una vez obtenidos los grupos de clientes mediante la técnica de clustering, se aplicó el Análisis de Componentes Principales (PCA) con el objetivo de representar gráficamente y analizar la estructura de los clusters generados.

El PCA permite proyectar los datos originales en un espacio de menor dimensión, conservando la mayor cantidad posible de variabilidad. De esta manera, facilita la visualización de los individuos y la identificación de patrones de agrupamiento que pueden resultar difíciles de observar en el espacio original de variables.

En este contexto, el análisis no tiene como finalidad seleccionar variables ni reemplazar los datos originales utilizados para la construcción de los clusters, sino proporcionar una herramienta de apoyo para evaluar la separación entre grupos, interpretar las principales fuentes de variabilidad y comprender qué variables contribuyen en mayor medida a las diferencias observadas entre los segmentos identificados.

Para realizar este análisis mostraremos la varianza explicada por cada componente principal, el gráfico de sedimentación y el análisis de las cargas factoriales, con el propósito de interpretar la estructura subyacente de los clusters obtenidos.

AutoValores

Componente	Varianza (Autovalor)	Varianza explicada (%)
1	3.525668	39.166922
2	1.225456	13.613691
3	1.051570	11.681971
4	0.939722	10.439448
5	0.834594	9.271566
6	0.623919	6.931161
7	0.378249	4.202003
8	0.328629	3.650764
9	0.093840	1.042474

Table 34: Autovalores y varianza explicada por cada componente principal.

La tabla de varianza explicada evidencia que la primera componente principal concentra una pro-

porción significativa de la información contenida en los datos, explicando aproximadamente el 39,17% de la variabilidad total. Este resultado indica que una parte importante de las diferencias observadas entre los clientes puede resumirse en una única dimensión.

Las componentes segunda y tercera aportan un 13,61% y un 11,68% adicional de la varianza total, respectivamente. En conjunto, las tres primeras componentes explican aproximadamente el 64,46% de la variabilidad observada, lo que permite obtener una representación simplificada de los datos conservando gran parte de la información original.

Asimismo, los tres primeros componentes presentan eigenvalues superiores a 1, cumpliendo con el criterio de Kaiser, mientras que a partir de la cuarta componente la capacidad explicativa disminuye progresivamente, indicando una menor contribución a la estructura general de los datos.

AutoVectores

Componente	Variable 1	Variable 2	Variable 3	Variable 4	Variable 5	Variable 6	Variable 7	Variable 8	Variable 9
Componente 1	0.068344	0.382053	0.352061	0.481394	0.455479	0.184237	0.378824	0.321233	-0.074662
Componente 2	-0.066367	0.146016	-0.362436	-0.175418	-0.190184	0.734001	0.437043	-0.189666	-0.101174
Componente 3	0.713630	0.059891	-0.067710	-0.085739	-0.106301	-0.033367	-0.098057	0.110803	-0.664006
Componente 4	0.661494	-0.053322	0.037492	-0.057808	-0.068870	0.147005	0.053285	0.086042	0.719888
Componente 5	-0.149329	-0.457779	0.451472	-0.228490	-0.278202	0.287713	0.039739	0.583959	-0.096657
Componente 6	-0.139714	0.511526	-0.422022	-0.162764	-0.204698	-0.183086	-0.080421	0.646162	0.121706
Componente 7	0.035031	-0.076111	0.056964	-0.128455	-0.250701	-0.535305	0.787571	-0.057152	-0.017245
Componente 8	-0.031843	0.583245	0.585302	-0.195278	-0.418840	0.033067	-0.147168	-0.281679	0.024034
Componente 9	-0.004797	-0.095375	-0.104645	0.770364	-0.618668	0.025102	-0.055307	0.003657	0.003999

Table 35: Autovectores correspondientes a los componentes principales.

El análisis de los autovectores revela cómo se configuran los nuevos componentes principales a partir de las variables originales. El Componente 1 actúa como un factor global, donde las Variables 4 y 5 ejercen la mayor influencia, acompañadas por un impacto significativo de las Variables 2, 7 y 3, lo que sugiere que este componente captura la actividad general del cliente. Por otro lado, el Componente 2 se aleja de esta visión global para enfocarse en un perfil específico dominado por las Variables 6 y 7, mientras que el Componente 3 establece una distinción clara al oponer el peso de la Variable 1 contra el de la Variable 9. Finalmente, el Componente 4 consolida esta segmentación al combinar el efecto conjunto de las Variables 9 y 1. En conjunto, mientras que el primer componente mide el volumen de actividad, los componentes subsiguientes permiten aislar comportamientos particulares que resultan determinantes para diferenciar los perfiles de los clientes en el análisis.

Gráfico de sedimentación (Scree Plot)




Figure 106: Scree Plot.

El gráfico de sedimentación confirma los resultados observados en la tabla de varianza explicada. Se aprecia una caída pronunciada entre la primera y la segunda componente, seguida de una disminución más gradual en las componentes restantes.

El punto de inflexión o "codo" de la curva se ubica entre la primera y la segunda componente, sugiriendo que una parte importante de la información se encuentra concentrada en las primeras dimensiones. Sin embargo, considerando la varianza acumulada, las tres primeras componentes resultan especialmente relevantes, ya que permiten representar aproximadamente el 64,5% de la variabilidad total del conjunto de datos.

Por lo tanto, estas componentes constituyen una base adecuada para visualizar e interpretar la distribución de los clientes y la separación existente entre los clusters identificados.




Figure 107: Gráfico de dispersión primeros dos componentes.

Se puede observar que al cruzar los dos primeros componentes, que explican una variabilidad de más del 50%, se pueden claramente diferenciar a ambos clusters.




Figure 108: Gráfico de dispersión primeros tres componentes.

Al realizar un gráfico en 3D, cruzando los primeros tres componentes que representan una variabilidad total del 64,5%, nuevamente podemos observar que los dos grupos están bien diferenciados.

Conclusión El Análisis de Componentes Principales permitió representar la estructura de los datos en un espacio de menor dimensión, facilitando la interpretación de los resultados obtenidos mediante clustering. La primera componente principal explica aproximadamente el 39,16% de la variabilidad total, mientras que las tres primeras componentes acumulan cerca del 64,45% de la información contenida en el conjunto de datos.

Los resultados obtenidos indican que gran parte de la variabilidad puede resumirse en un número reducido de dimensiones, permitiendo visualizar de forma más clara la distribución de los clientes y las diferencias existentes entre los grupos identificados.

En este contexto, el PCA fue utilizado como una herramienta de apoyo para la interpretación y validación de los clusters generados. El análisis de las componentes principales permitió identificar

las variables con mayor influencia en la segmentación observada, aportando una mejor comprensión de las características que distinguen a cada grupo de clientes y fortaleciendo la interpretación de los resultados obtenidos mediante las técnicas de clustering.